间歇方位观测下异中心神经场集群运动的 Kalman 预测补偿方法

摘要

异中心（allocentric）环形吸引子模型能够仅依靠邻居方位输入产生集群有序运动，其性能依赖连续且可靠的社会感知。局部遮挡或通信中断导致邻居方位观测间歇缺失时，神经场输入减少或发生方向偏差，进而影响运动有序性和集群结构。本文在 Salahshour 与 Couzin 的异中心神经场模型基础上，提出基于指数方位权重的邻居社会输入经验量化模型，统一表征邻居数量、输入强度与相对自身朝向的方位结构。三个局部神经场实验验证其数量–强度累加关系和方位加权特征；在 20 组随机几何、240 个配对条件的分组交叉验证中，该指标较总幅值基准降低纵向响应预测 RMSE 16.1%。随后建立方位–方位角速度二状态 Kalman 预测器，在缺失期间外推已跟踪邻居方位，并将预测协方差通过周期核卷积传递至神经场输入。理论分析给出连续缺失期间的方位协方差增长、圆周方向信息衰减及条件均方输入重建性质。采用方位预测、同状态输入重建与闭环响应的分层评价，五种子开发实验在遮挡半数邻居、总幅值 0.228 的条件下，均值预测较保持旧方位降低输入场重建误差 61.8%。扩展闭环实验比较观测删除、最后方位保持、Kalman 均值预测和协方差感知预测，并通过遮挡前受控转向检验方向跟随过程。结果表明，在固定身份、等权、模型原定单边增益条件下，Kalman 补偿能够降低连续缺失造成的相对性能偏差；阻尼角速度 KF 进一步降低隐藏边的方位预测误差。

关键词：异中心表征；环形吸引子；集群运动；间歇观测；Kalman 滤波；方位预测；不确定性传播

1 引言

无人集群通过多个自主个体的局部感知、相互协同和分布式决策，能够完成单体平台难以承担的大范围、长时程和高风险任务。在灾害监测与应急搜救中，多无人机集群可在有限视场和避障约束下完成协同覆盖与目标搜寻 [1]；在林下环境巡检与农业作业中，分布式集群控制能够提高复杂环境中的队形保持和环境适应能力 [2]；在通信中继等场景中，个体通信障碍会直接影响集群凝聚和任务执行 [3]，而间歇采样和通信条件下的协调控制则是维持区域覆盖与群体协同的关键 [4]。因此，无人集群在上述领域具有重要应用价值。

若按决策所依赖的信息和计算组织方式划分，多智能体协同控制可分为集中式与分布式两类。集中式方法汇集个体状态并统一计算控制指令，便于协调全局任务，但需要持续获取和传递群体信息；分布式方法则由各个体依据本地观测及可获得的邻居信息更新自身行为 [5]。对于需要持续协同运动的无人集群，后者能够将群体协调建立在局部交互之上，但其运动效果也取决于邻居信息的可获得性和表达方式。由局部交互产生有序集体运动的 flocking，因而成为研究这一问题的典型模型。

flocking 建模关注局部交互如何产生有序的集体运动。Reynolds 在 1987 年发表的 Boids 模型通过分离、对齐和凝聚三类局部行为模拟群体运动 [6]；Vicsek 等人在 1995 年通过局部航向对齐建立自驱动粒子模型，研究集体运动的有序相变 [7]；Olfati–Saber 于 2006 年将 flocking 写成分布式控制律，并建立相应的算法与理论分析框架 [5]。这些研究从行为规则和控制律出发描述群体运

动。Salahshour 与 Couzin（2025）进一步从方位信息的神经表征出发，将邻居方位映射到环形吸引子网络，比较自我中心与异中心表征对集体运动的影响。本文采用其中神经场模型（neural field model）的异中心表征版本，后文简称“异中心神经场模型”[8]。该模型仅依靠邻居方位输入即可产生有序集体运动，为研究社会输入与群体运动的关系提供了具体机制。

在实际感知与通信过程中，遮挡和链路中断会使邻居方位观测间歇缺失。删除缺失邻居会同时改变总输入幅值与方位结构；保持最后一次观测则可能在群体转向时持续提供过期方向。因此，需要量化邻居信息对社会输入的作用，并利用历史方位重建缺失期间的方向输入。

本文研究间歇仅方位观测下的社会输入量化与预测补偿，围绕这一目标提出三个递进的科学问题。其一，辨明邻居数量、总输入幅值和方位结构各自对群体有序性与凝聚性的作用，识别观测缺失造成的信息损失。其二，如何利用历史方位预测缺失期间的邻居方向，并将预测不确定性映射为神经场输入。其三，预测重建的社会输入如何影响群体有序运动与凝聚结构。

这些问题的主要挑战在于：邻居数量变化通常伴随总输入强度变化，而相同总幅值的输入又会因方位分布不同产生不同的方向作用；连续观测缺失使方向预测与不确定性随时间演化；输入层的重建效果还需通过群体运动响应加以评估。

为回答第一个问题，本文提出基于指数方位权重的邻居社会输入经验量化模型，通过累加单邻居输入，统一表征邻居数量、输入强度与相对自身朝向的方位信息。

针对第二个问题，本文提出基于历史方位预测的神经场输入重建方法，将预测均值与协方差映射为周期方向输入，并通过方位预测、同状态输入重建和闭环响应的分层实验，辨别幅值恢复、方位记忆与方向外推的作用。

针对第三个问题，本文通过配对仿真实验比较删除输入、保持旧方位与 Kalman 预测补偿，评估方位预测精度以及群体有序性和凝聚性的变化。

2 问题描述

2.1 问题描述

考虑 N 个智能体在边长 L 的二维周期区域内运动。每个智能体 i 具有物理状态

$$(q_i(k), \phi_i(k)), \tag{1}$$

其中 $q_i(k) = [x_i(k), y_i(k)]^\top$ 是位置，$\phi_i(k)$ 是世界坐标系中的自身朝向。每个智能体同时维护一个包含 M 个方向单元的环形神经场状态 $u_i(k) \in \mathbb{R}^M$ 和固定方向偏好

$$\alpha_m = \frac{2\pi m}{M} + \phi_{i,0}, \qquad m = 0, \dots, M-1, \tag{2}$$

其中 $\phi_{i,0}$ 是初始化方向偏移。该表示是异中心的，即神经元方向固定在共同世界坐标系中，不随智能体自身朝向旋转。

智能体不能直接获得邻居位置，也不具有距离传感器。对于每条有向邻居边 (i, j)，传感器可能输出机体坐标系中的方位

$$z_{ij}^b(k) = \mathrm{wrap}\left(\theta_{ij}(k) - \phi_i(k) + \nu_{ij}(k)\right), \tag{3}$$

其中 $\theta_{ij}(k)$ 是邻居的世界方位，$\nu_{ij}(k) \sim \mathcal{N}(0, R)$ 是测量噪声。定义观测指示量

$$\delta_{ij}(k) = \begin{cases} 1, & \text{第 } k \text{ 步获得邻居 } j \text{ 的新鲜方位,} \\ 0, & \text{观测缺失或通信中断.} \end{cases} \tag{4}$$

已知自身朝向时，可将测量转换到世界坐标系：

$$z_{ij}(k) = \mathrm{wrap}(z_{ij}^b(k) + \phi_i(k)). \tag{5}$$

本文的问题可以描述为：在间歇方位观测条件下 [9]，利用截至当前时刻的观测历史构造因果预测与输入重建接口，在缺失期间延续邻居方向信息，并评价群体有序运动、凝聚结构和转向跟随能力。邻居真值用于离线评价，控制输入由观测及预测构成。

该问题的输入和输出如表 1 所示。

表 1: 问题描述中的控制器输入与输出

层级	输入	输出
传感器层	自身朝向 $\phi_i(k)$；已关联邻居编号 j；新鲜方位 $z_{ij}(k)$；观测指示量 $\delta_{ij}(k)$	经过噪声和遮挡处理后的方位观测
预测层	当前边历史观测 $z_{ij}(0:k)$；上一步估计 $\hat{x}_{ij}(k-1)$ 和协方差 $P_{ij}(k-1)$	预测方位均值 $\mu_{ij}(k)$；方位方差 $V_{ij}(k)$；轨迹有效指示量 $m_{ij}(k)$
神经场层	神经元方向 α_m；神经场状态 $u_i(k)$；预测方位及方差	外部社会输入 $I_i(k)$；更新后的神经活动 $u_i(k+1)$
运动层	正神经活动 $a_{im}(k)$；速度尺度 v_s	运动速度 $v_i(k)$；更新位置 $q_i(k+1)$

令 $\mathcal{Z}_i(0:k) = \{(j, z_{ij}(t), \delta_{ij}(t)) : t \le k\}$ 表示智能体 i 截至第 k 步的全部可用观测历史。控制器的目标可以写为

$$\min_{\Pi} \ \mathbb{E}\left[\left\| I_i^{\mathrm{true}}(k) - \Pi(\mathcal{Z}_i(0:k), u_i(k); \Theta)\right\|_2^2\right], \tag{6}$$

其中 Π 是满足因果性约束的预测输入重建接口，Θ 是滤波器参数，I_i^{true} 是如果所有邻居方位均新鲜时异中心神经场模型将获得的社会输入。除输入重建误差外，闭环性能还由 GO、LO、凝聚距离、转向跟随误差和恢复时间评价。

本文进一步假设：

(1) 邻居编号已经正确关联，不考虑错误匹配和轨迹交换；

(2) 自身朝向 $\phi_i(k)$ 已知，不考虑自身朝向估计误差；

(3) 传感器只提供方位，不提供距离，因此不允许使用二维位置—速度滤波器；

(4) 预测接口使用截至当前时刻的历史观测，隐藏真值和未来状态用于离线评价。

2.2 异中心神经场模型的求解

本节给出 Salahshour 与 Couzin（2025）神经场模型的异中心表征版本 [8] 的求解过程。该模型使用连续可得的邻居方位和全邻居交互。对每个智能体 i，其社会邻居集合固定为

$$\mathcal{B}_i = \{j \in \{1, \dots, N\} : j \neq i\}. \tag{7}$$

对邻居 j，采用周期区域中的最小镜像差分

$$r_{ij}(k) = q_j(k) - q_i(k) - L\,\mathrm{round}\left(\frac{q_j(k) - q_i(k)}{L}\right). \tag{8}$$

其真实世界方位为

$$\theta_{ij}(k) = \mathrm{atan2}(r_{ij,y}(k), r_{ij,x}(k)). \tag{9}$$

定义圆周角距离

$$d_{\mathbb{S}^1}(a, b) = |\mathrm{wrap}(a - b)|, \quad \mathrm{wrap}(x) = \mathrm{mod}(x + \pi, 2\pi) - \pi. \tag{10}$$

完整新鲜社会输入为

$$I_{im}^{\mathrm{soc}}(k) = h_0 \sum_{j \in \mathcal{B}_i} g_\sigma\left(\alpha_m - \theta_{ij}(k)\right), \quad h_0 = \frac{h_t}{N}, \tag{11}$$

其中

$$g_\sigma(x) = \exp\left[-\frac{d_{\mathbb{S}^1}^2(x, 0)}{2\sigma_s^2}\right]. \tag{12}$$

这里 $\mathcal{B}_i$ 是固定全邻居集合。实际幅值总和为 $(N-1)h_t/N$。

环形连接矩阵与神经场更新分别为

$$W_{mn} = \cos\left[\pi\left(\frac{d_{mn}}{\pi}\right)^\zeta\right], \tag{13}$$

$$u_i(k+1) = u_i(k) + \Delta t\left[-u_i(k) + \frac{1}{M} W \tanh(\beta u_i(k)) - h_b \mathbf{1} + I_i(k)\right]. \tag{14}$$

神经场内部使用未截断的 tanh。运动解码时定义正活动

$$a_{im}(k) = \max\{\tanh(\beta u_{im}(k)), 0\}, \tag{15}$$

并令

$$c_i(k)=\sum_{m=0}^{M-1}a_{im}(k)e^{\mathrm{i}\alpha_m},\quad v_i(k)=v_s[\Re c_i(k),\Im c_i(k)]^\top, \tag{16}$$

$$q_i(k+1)=\mathrm{mod}(q_i(k)+\Delta t v_i(k),L). \tag{17}$$

因此 v_s 是速度尺度而不是恒定速度。单环活动集中度定义为

$$\kappa_i(k)=\frac{|c_i(k)|}{\sum_m a_{im}(k)+\varepsilon}. \tag{18}$$

上述环形连接与活动峰动力学与头方向细胞群的空间朝向表征 [10] 相一致。自适应环形吸引子模型进一步表明，外部线索可调制以自我为中心的方向编码 [11]；从连续神经动力学角度，相关研究讨论了预测性神经网络动力学 [12]，人脑自然导航实验也为周期方向表征提供了神经罗盘证据 [13]。

异中心神经场模型的完整求解流程见算法 1。

算法 1 异中心神经场模型的求解流程

输入： 模型参数 $N,M,L,\Delta t,v_s,\beta,\sigma_s,h_t,h_b,\zeta$

输入： 初始状态 $q_i(0)$、$\phi_i(0)$、$u_i(0)$，或用于随机初始化的随机种子

输出： 轨迹 $\{q_i(k)\}_{i=1,k=0}^{N,K}$、神经状态 $\{u_i(k)\}_{i=1,k=0}^{N,K}$ 和社会输入历史 $\{I_i(k)\}$

初始化 $q_i(0)\sim\mathcal{U}([0,L)^2)$，$\phi_i(0)\sim\mathcal{U}(0,2\pi)$，$u_i(0)=0.1\epsilon_i$，$\epsilon_i\sim\mathcal{N}(0,I_M)$
设置 $\alpha_m=2\pi m/M+\phi_i(0)$，并在后续时刻保持固定
对于 $k=0,1,\ldots,K-1$ **执行**
    对于 所有 $i=1,2,\ldots,N$，并行 **执行**
        $\mathcal{B}_i\leftarrow\{j:j\neq i\}$
        对于 $j\in\mathcal{B}_i$ **执行**
            计算周期差分 $r_{ij}(k)$ 和世界方位 $\theta_{ij}(k)$
            将邻居方位累加到圆周高斯输入 $I_{im}^{\mathrm{soc}}(k)$
        结束 对于
        $I_i(k)\leftarrow I_i^{\mathrm{soc}}(k)$
        $u_i(k+1)\leftarrow u_i(k)+\Delta t\left[-u_i(k)+\frac{1}{M}W\tanh(\beta u_i(k))-h_b\mathbf{1}+I_i(k)\right]$
        计算正活动 $a_{im}(k)$ 和复数合矢量 $c_i(k)$
        解码速度 $v_i(k)=v_s[\Re c_i(k),\Im c_i(k)]^\top$
    结束 对于
    对于 所有 $i=1,2,\ldots,N$，并行 **执行**
        更新位置 $q_i(k+1)=\mathrm{mod}(q_i(k)+\Delta t v_i(k),L)$
    结束 对于
结束 对于
返回 $\{q_i(k)\}$、$\{u_i(k)\}$、$\{I_i(k)\}$

算法 1 对应异中心神经场模型的全邻居版本，其中所有个体均使用同一时刻的位置计算输入，并在该时间步结束时同步更新。GO、LO、凝聚距离和活动集中度等指标不参与状态更新，而是由返回的轨迹和神经状态离线计算。

本文以全邻居、等权交互的异中心神经场模型为基础。邻居选择还可能受视觉线索 [14]、注意力机制 [15] 和选择性交互 [16] 影响；为拆分数量、强度和方位的作用，下面对给定邻居集合建立统一的输入表征。

2.3 邻居社会输入的经验量化模型

2.3.1 方位编码与单邻居输入

沿用 Salahshour 与 Couzin 的异中心方位编码 [8]，$\theta_{ij}(k)$ 表示从智能体 i 指向邻居 j 的方位，$\phi_i(k)$ 表示自身运动朝向，二者均在同一固定参照系下表达。本文取机体前向轴与运动朝向一致，此时无噪声机体方位满足 $z_{ij}^b(k) = \mathrm{wrap}(\theta_{ij}(k) - \phi_i(k))$。定义自身朝向和邻居方位的单位向量

$$e_i(k) = \begin{bmatrix} \cos\phi_i(k) \\ \sin\phi_i(k) \end{bmatrix}, \qquad b_{ij}(k) = \begin{bmatrix} \cos\theta_{ij}(k) \\ \sin\theta_{ij}(k) \end{bmatrix}. \tag{19}$$

其中 b_{ij} 描述邻居相对自身的位置方位。单位内积 $e_i^\top b_{ij} = \cos(\theta_{ij} - \phi_i)$ 表示该方位与自身朝向的接近程度，计算时只需邻居方位和自身朝向。

本文采用指数余弦函数定义方位权重

$$f_\kappa(\psi) = \frac{\exp(\kappa\cos\psi)}{\exp(\kappa)} = \exp[\kappa(\cos\psi - 1)], \qquad \kappa > 0. \tag{20}$$

参数 κ 控制方位权重的集中程度，κ 越大，权重越集中于正前方；分母 $\exp(\kappa)$ 将最大权重归一化为 1。本文取 $\kappa = 1$，此时 $f_1(\psi) = \exp(\cos\psi)/e$。

令 $w_{ij}(k) \geq 0$ 为邻居 j 对神经场的实际输入强度，即方向高斯核前的系数；等权设置取 $w_{ij} = h_0$。单邻居社会输入定义为

$$\boxed{s_{ij}(k) = w_{ij}(k) f_\kappa(\theta_{ij}(k) - \phi_i(k)).} \tag{21}$$

该量将输入强度与方位权重相乘，使接近自身当前运动朝向的邻居方位具有更高权重。当 $\kappa = 1$ 时，正前方、正侧方和正后方邻居分别贡献 w_{ij}、$e^{-1}w_{ij} \approx 0.368w_{ij}$ 和 $e^{-2}w_{ij} \approx 0.135w_{ij}$；具有正输入强度的邻居在各个方位均保留正贡献。

2.3.2 总社会输入与因素分解

对当前参与输入的邻居集合 $\mathcal{N}_i(k)$ 求和，得到总社会输入经验量化公式

$$\boxed{S_i(k) = \sum_{j\in\mathcal{N}_i(k)} w_{ij}(k)\exp\{\kappa\left[\cos(\theta_{ij}(k) - \phi_i(k)) - 1\right]\}.} \tag{22}$$

邻居数量通过求和项数体现。定义邻居数 $n_i = |\mathcal{N}_i|$、总输入幅值 A_i、平均单邻居强度 $\bar{w}_i$ 和归一化方位权重 C_i：

$$A_i = \sum_{j\in\mathcal{N}_i} w_{ij}, \qquad \bar{w}_i = \frac{A_i}{n_i}, \tag{23}$$

$$C_i = \sum_{j\in\mathcal{N}_i} \frac{w_{ij}}{A_i} f_\kappa(\theta_{ij} - \phi_i), \qquad e^{-2\kappa} \leq C_i \leq 1. \tag{24}$$

在 $n_i > 0$、$A_i > 0$ 时，式 (22) 可写为

$$\boxed{S_i = A_i C_i = n_i \bar{w}_i C_i.} \tag{25}$$

无有效输入时取 $S_i = 0$、$C_i = 0$。总量 S_i 保留邻居数量和强度的累加作用，归一化量 C_i 描述给定总幅值下的方位加权结构。固定单邻居强度和方位加权结构时，增加邻居数使 S_i 线性增加；固

定邻居数和方位时，整体放大输入强度使 S_i 同比例缩放；固定总幅值时，方位变化通过 C_i 改变 S_i。

群体仿真由完整的社会输入场驱动神经活动：

$$I_i^{\mathrm{soc}}(\alpha,k)=\sum_{j\in\mathcal{N}_i(k)} w_{ij}(k)g_\sigma(\alpha-\theta_{ij}(k)). \tag{26}$$

A_i 是核系数之和，其与输入场积分之间的比例由核宽度决定；S_i 对邻居输入按相对自身朝向的方位进行加权，表征数量、强度和方位的共同作用。实验以总幅值 A_i 为基准，比较加入方位权重后的 S_i 对局部神经场运动响应的解释能力。完整输入场仍用于驱动神经活动，经验量 S_i 用于描述和分析输入。

2.4 间歇观测下的社会输入变化与补偿需求

异中心神经场模型使用连续可得的邻居方位输入。遮挡或通信中断会改变输入的幅值与方位结构，本文利用第 2.3 节的经验模型量化这些变化，并据此组织预测补偿需求。

社会输入缺失 若直接删除缺失邻居，则

$$I_i^{\mathrm{drop}}(k)=h_0\sum_{j\in\mathcal{B}_i(k)}\delta_{ij}(k)g_\sigma(\alpha_m-\theta_{ij}(k)). \tag{27}$$

删除输入同时降低输入总幅值并改变方位覆盖，使神经场活动的强度和方向分布随剩余邻居发生变化。

过期方位造成错误峰 若保持最后一次观测方位，则输入幅值可以维持，但方向可能已经过期：

$$\hat{\theta}_{ij}(k)=z_{ij}(k_{\mathrm{last}}),\quad k-k_{\mathrm{last}}>0. \tag{28}$$

在群体转向时，过期方位会把神经活动峰持续固定在旧方向，形成“幽灵邻居输入”，使个体无法及时跟随方向变化。

缺失信息的量化分解 在同一时刻、以同一自身朝向为参考，记完整新鲜输入的幅值与归一化方位权重为 A_i、C_i，实际可用或重建输入的对应量为 $\widehat{A}_i$、$\widehat{C}_i$，则社会输入差异为

$$\Delta S_i=S_i-\widehat{S}_i=(A_i-\widehat{A}_i)C_i+\widehat{A}_i(C_i-\widehat{C}_i). \tag{29}$$

第一项描述总幅值变化的贡献，第二项描述归一化方位权重变化的贡献。删除输入时，缺失集合 $\mathcal{H}_i$ 造成的社会输入损失为

$$\Delta S_i^{\mathrm{drop}}=\sum_{j\in\mathcal{H}_i} w_{ij}f_\kappa(\theta_{ij}-\phi_i)\geq 0. \tag{30}$$

保持旧方位时，输入幅值维持为 A_i，差异来自当前方位与旧方位的指数权重变化。以 $|\Delta S_i|$ 衡量社会输入量化误差，可将缺失邻居数、损失强度和方位变化连接到同一个可计算量；幅值项和方位项分别保留符号，用于辨别两种变化的作用方向。

方位状态与局部可观测性 传感器提供邻居方位，局部预测状态据此选为方位及其时间变化率。连续不同时刻的方位观测用于识别局部角速度，自身朝向用于将观测转换至异中心参照系。

轨迹生命周期和数据关联问题 遮挡期间必须区分“暂时没有观测但目标仍可能存在”和“目标已经离开或轨迹失效”。如果轨迹无限保留，会累积错误预测；如果过早删除，重新出现时又需要重新初始化。因此需要观测年龄、预测方差和有效集合 $m_{ij}(k)$ 的管理机制。分布式多传感器多目标滤波为间歇观测下的轨迹维持提供了参考 [17]；对于纯方位目标，交互式多模型与无迹信息滤波可用于处理轨迹存在性和跟踪不确定性 [18]。

转向响应评价 群体进入直线运动后，既有航向惯性可维持较高 GO。本文设置遮挡前受控转向，激发邻居方位的时间变化，并报告相对无遮挡控制的 GO、LO、凝聚距离和恢复误差。

近距离风险诊断 异中心神经场模型通过方位输入组织运动。本文以最小距离和危险接近比例诊断近距离风险，并将其与有序度和凝聚恢复分别评价；显式避碰约束作为后续控制扩展。

3 间歇方位观测下的 Kalman 预测与神经场输入补偿

邻居方位观测的间歇缺失会减少神经场的社会输入，并改变其方向结构。为在有限缺失窗口内延续已观测邻居的方向信息，本文建立由方位状态估计、缺失期间预测和神经场输入重建组成的补偿方法。每个智能体独立维护其已跟踪邻居的方位–方位角速度状态：观测到达时执行 Kalman 更新，观测缺失时保留模型预测，并将预测均值及协方差映射为神经场的周期方向输入。

3.1 方法概述与观测模型

设 $\delta_{ij}(k) \in \{0,1\}$ 表示观测是否新鲜到达。若传感器在机体坐标系中输出方位，且自身世界朝向 $\phi_i(k)$ 已知，则

$$z_{ij}^{b}(k) = \mathrm{wrap}(\theta_{ij}(k) - \phi_i(k) + \nu_{ij}(k)), \tag{31}$$

$$z_{ij}(k) = \mathrm{wrap}(z_{ij}^{b}(k) + \phi_i(k)), \quad \nu_{ij}(k) \sim \mathcal{N}(0, R). \tag{32}$$

仅当 $\delta_{ij}(k) = 1$ 时执行测量更新。本文假设邻居目标编号正确，尚不处理数据关联错误和自身朝向误差。

3.2 方位状态预测与测量更新

3.2.1 方位–方位角速度状态与阻尼扩展

由于没有距离观测，定义局部展开角状态

$$x_{ij}(k) = \begin{bmatrix} \vartheta_{ij}(k) \\ \omega_{ij}(k) \end{bmatrix}, \quad \theta_{ij}(k) = \mathrm{wrap}(\vartheta_{ij}(k)), \tag{33}$$

其中 $\vartheta_{ij}(k)$ 是局部展开角，$\theta_{ij}(k)$ 是其对应的圆周方位，$\omega_{ij}(k)$ 是邻居相对于观测者的方位角速度，并非邻居自身航向的角速度。基础模型采用局部常角速度假设

$$x_{ij}(k+1) = F x_{ij}(k) + w_{ij}(k), \quad F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}, \tag{34}$$

$$Q = q_\omega \begin{bmatrix} (\Delta t)^3/3 & (\Delta t)^2/2 \\ (\Delta t)^2/2 & \Delta t \end{bmatrix}, \quad z_{ij}(k) = H x_{ij}(k) + \nu_{ij}(k), \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix}. \tag{35}$$

为提高长时间缺失下的外推稳定性，进一步采用阻尼角速度模型作为扩展。令 $\rho = \exp(-\Delta t/\tau)$，其中 τ 为角速度相关时间，则

$$x_{ij}(k+1) = F_{\mathrm{GM}} x_{ij}(k) + w_{ij}(k), \quad F_{\mathrm{GM}} = \begin{bmatrix} 1 & \tau(1-\rho) \\ 0 & \rho \end{bmatrix}, \tag{36}$$

$$Q_{\mathrm{GM}} = q_\omega \begin{bmatrix} \tau^2\Delta t - \tau^3\left(2(1-\rho) - \frac{1-\rho^2}{2}\right) & \frac{\tau^2(1-\rho)^2}{2} \\ \frac{\tau^2(1-\rho)^2}{2} & \frac{\tau(1-\rho^2)}{2} \end{bmatrix}. \tag{37}$$

当 $\tau \to \infty$ 时，该模型退化为常角速度模型；当 τ 较小时，角速度预测向零衰减，从而降低长时间外推对过期角速度的依赖。上述模型只预测方位，不恢复邻居的二维位置或速度。当过程模型参数或噪声比例难以准确给定、且模型失配主要来自参数比例时，可采用自适应 Kalman 滤波思想在线调整噪声强度 [19]。

3.2.2 初始化、预测与更新

首次收到目标观测时初始化

$$\hat{x}_{ij}(k) = \begin{bmatrix} z_{ij}(k) \\ 0 \end{bmatrix}, \quad P_{ij}(k) = \mathrm{diag}(R, P_{\omega,0}). \tag{38}$$

对已初始化轨迹先执行

$$\hat{x}_{ij}^{-}(k) = F\hat{x}_{ij}(k-1), \qquad P_{ij}^{-}(k) = FP_{ij}(k-1)F^{\top} + Q. \tag{39}$$

当 $\delta_{ij}(k) = 1$ 时，计算圆周创新

$$e_{ij}(k) = \mathrm{wrap}\left(z_{ij}(k) - H\hat{x}_{ij}^{-}(k)\right), \tag{40}$$

$$S_{ij} = HP_{ij}^{-}H^{\top} + R, \quad K_{ij} = P_{ij}^{-}H^{\top}S_{ij}^{-1}, \tag{41}$$

$$\hat{x}_{ij}(k) = \hat{x}_{ij}^{-}(k) + K_{ij}e_{ij}(k), \tag{42}$$

$$P_{ij}(k) = (I - K_{ij}H)P_{ij}^{-}(k)(I - K_{ij}H)^{\top} + K_{ij}RK_{ij}^{\top}. \tag{43}$$

对于少量异常方位观测，还可借鉴最大似然最大相关熵准则抑制非高斯重尾噪声对状态更新的影响 [20]；本文主实验仍采用高斯测量模型，以便与神经场输入保持一致。

当 $\delta_{ij}(k) = 0$ 时跳过更新，仅保留预测值。记观测年龄为 $a_{ij}(k)$，成功更新时置零，连续缺失时每步增加 Δt。当 $a_{ij}(k) > \tau_{\max}$ 时删除轨迹，后续重新获得观测时重新初始化。记轨迹有效标记为 $m_{ij}(k) \in \{0, 1\}$，其中观测指示量 $\delta_{ij}(k)$ 控制是否执行测量更新，$m_{ij}(k)$ 控制是否向神经场注入该邻居的方向输入。这种在随机丢包期间保留预测、恢复后重新利用轨迹的处理与网络化系统中的丢包补偿思想一致 [21]。在分布式实现中，还可采用自适应通信策略降低信息交换需求 [22]，或在随机通信协议下通过一致性滤波保持节点估计一致 [23]；融合多源测量协方差能够进一步提高共同估计精度 [24]。

观测矩阵为

$$\mathcal{O} = \begin{bmatrix} H \\ HF \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & \Delta t \end{bmatrix}. \tag{44}$$

当 $\Delta t \neq 0$ 时 $\det(\mathcal{O}) = \Delta t \neq 0$，说明连续不同时间的方位观测可识别局部二状态模型；单次方位观测不能直接识别角速度。若方位观测与状态之间的关系出现更强非线性，可进一步采用无迹 Kalman 滤波类方法处理均值与协方差的非线性传播 [25]。

3.3 不确定性感知神经场输入

3.3.1 预测均值输入

定义

$$\mu_{ij}(k) = H\hat{x}_{ij}(k), \quad V_{ij}(k) = HP_{ij}(k)H^{\top}. \tag{45}$$

若轨迹已经初始化且未过期，记 $m_{ij}(k) = 1$，否则为零。最小预测均值输入为

$$I_{im}^{\mathrm{mean}}(k) = h_0 \sum_j m_{ij}(k) g_\sigma(\alpha_m - \mu_{ij}(k)), \tag{46}$$

其中 g_σ 为第 2.2 节定义的圆周高斯核，δ_{ij} 控制是否更新滤波器，m_{ij} 控制预测轨迹是否继续注入神经场。在第 5.5 节的无噪声机制实验中，新鲜边直接使用当前方位，缺失边采用预测均值与最后合法权重，得到

$$I_{im}^{\mathrm{mix}}(k) = \sum_{j\in\mathcal{F}_i(k)} w_{ij}(k) g_\sigma(\alpha_m - z_{ij}(k)) + \sum_{j\in\mathcal{H}_i(k)} w_{ij}(k_{\mathrm{last}}) g_\sigma(\alpha_m - \mu_{ij}(k)), \tag{47}$$

其中 $\mathcal{F}_i$ 为新鲜观测集合，$\mathcal{H}_i$ 为已经初始化且当前缺失的邻居集合。新鲜观测既驱动当前输入，也更新预测器；缺失边通过历史观测形成的状态外推继续提供方向输入。

3.3.2 协方差传播与周期卷积

在局部高斯假设下，方位后验为 wrapped normal 分布

$$\Theta_{ij}(k) \mid \mathcal{Y}_{i,k} \sim \mathrm{WN}(\mu_{ij}(k), V_{ij}(k)). \tag{48}$$

将社会输入定义为方位核的条件期望：

$$\bar{g}_\sigma(x; V) = \int_{-\pi}^{\pi} g_\sigma(x-\epsilon) p_{\mathrm{WN}}(\epsilon; 0, V)\, d\epsilon, \tag{49}$$

$$I_{im}^{\mathrm{unc}}(k) = h_0 \sum_j m_{ij}(k) \bar{g}_\sigma(\alpha_m - \mu_{ij}(k); V_{ij}(k)). \tag{50}$$

令

$$c_n = \frac{1}{2\pi} \int_{-\pi}^{\pi} g_\sigma(x) e^{-\mathrm{i}nx}\, dx, \tag{51}$$

则周期卷积的 Fourier 形式为

$$\bar{g}_\sigma(x; V) = \sum_{n=-\infty}^{\infty} c_n e^{-n^2 V/2} e^{\mathrm{i}nx}. \tag{52}$$

因此第 n 阶方向信息保留比例为 $e^{-n^2V/2}$，一阶方向信息保留比例为

$$\gamma(V) = e^{-V/2}. \tag{53}$$

当 V 增大时，输入方向结构变宽并趋向均匀背景，零阶 Fourier 分量保持不变，即总输入保留而方向集中度降低。

在方位分布足够集中时，可采用便于实现的局部高斯近似

$$\bar{g}_\sigma(x; V) \approx \sqrt{\frac{\sigma_s^2}{\sigma_s^2 + V}} \exp\left[-\frac{\mathrm{wrap}(x)^2}{2(\sigma_s^2 + V)}\right]. \tag{54}$$

该式只适用于小方差和单一展开分支；大方差情形应使用周期积分或 Fourier 形式。

3.4 算法流程与伪代码

每个时间步首先接收并转换方位观测，然后对各邻居轨迹进行初始化、预测或测量更新。经过有效性检查后，轨迹的预测均值和协方差被映射为社会输入，最后驱动神经场与运动模型。各智能体使用同一时刻的状态同步推进，避免顺序更新产生额外的信息差异。

算法 2 间歇方位观测下的 Kalman 预测与神经场输入补偿

输入： 时间步长 Δt、测量噪声方差 R、初始角速度方差 $P_{\omega,0}$
输入： 状态模型 $\text{model} \in \{\text{CV}, \text{GM}\}$、输入模式 $\text{mode} \in \{\text{mean}, \text{uncertainty}\}$
输入： 过程噪声参数 q_ω、相关时间 τ、轨迹生命周期 $\tau_{\max}$
输入： 方向单元 α_m、核宽度 σ_s、单边输入幅值 h_0 及神经场参数
输出： 轨迹集合 $\mathcal{T}_i$、社会输入 $I_i(k)$ 和同步更新的神经场与运动状态
初始化所有轨迹集合 $\mathcal{T}_i \leftarrow \varnothing$
根据 model 构造状态矩阵 F 与过程噪声协方差 Q
if mode = uncertainty **then**
    预计算方向核 Fourier 系数 $c_0, \ldots, c_{N_F}$
结束 if

算法 2（续）：输入构造及闭环推进

对于 每个时间步 k **执行**
  从同一时刻的系统状态获取所有新鲜方位观测
  对于 每个智能体 i **执行**
    $I_i(k) \leftarrow \mathbf{0}$；$\mathcal{J}_i \leftarrow$ 已维护轨迹与当前观测邻居身份之并集
    对于 每个 $j \in \mathcal{J}_i$ **执行**
      if $\delta_{ij}(k) = 1$ **then**
        将机体系观测转换为世界方位 $z_{ij}(k)$
      结束 if
      if $j \notin \mathcal{T}_i$ **then**
        if $\delta_{ij}(k) = 0$ **then**
          跳过该邻居
        else
          $\hat{x}_{ij} \leftarrow [z_{ij}(k), 0]^\top$；$P_{ij} \leftarrow \mathrm{diag}(R, P_{\omega,0})$；$a_{ij} \leftarrow 0$
          将 j 加入 $\mathcal{T}_i$
        结束 if
      else
        $\hat{x}_{ij}^- \leftarrow F\hat{x}_{ij}$；$P_{ij}^- \leftarrow FP_{ij}F^\top + Q$
        if $\delta_{ij}(k) = 1$ **then**
          $e_{ij} \leftarrow \mathrm{wrap}(z_{ij}(k) - H\hat{x}_{ij}^-)$
          $S_{ij} \leftarrow HP_{ij}^-H^\top + R$；$K_{ij} \leftarrow P_{ij}^-H^\top S_{ij}^{-1}$
          $\hat{x}_{ij} \leftarrow \hat{x}_{ij}^- + K_{ij}e_{ij}$；$a_{ij} \leftarrow 0$
          $P_{ij} \leftarrow (I_2 - K_{ij}H)P_{ij}^-(I_2 - K_{ij}H)^\top + K_{ij}RK_{ij}^\top$
        else
          $\hat{x}_{ij} \leftarrow \hat{x}_{ij}^-$；$P_{ij} \leftarrow P_{ij}^-$；$a_{ij} \leftarrow a_{ij} + \Delta t$
        结束 if
        if $a_{ij} > \tau_{\max}$ **then**
          从 $\mathcal{T}_i$ 删除 j 并跳过该邻居
        结束 if
        $\mu_{ij} \leftarrow H\hat{x}_{ij}$；$V_{ij} \leftarrow HP_{ij}H^\top$
        对于 每个方向单元 m **执行**
          $x \leftarrow \mathrm{wrap}(\alpha_m - \mu_{ij})$
          if mode = mean **then**
            $b \leftarrow \exp[-x^2/(2\sigma_s^2)]$
          else
            $b \leftarrow c_0 + \sum_{n=1}^{N_F} 2c_n \exp(-n^2V_{ij}/2)\cos(nx)$
          结束 if
          $I_{im}(k) \leftarrow I_{im}(k) + h_0 b$
        结束 对于
      结束 if
    结束 对于
    将 $I_i(k)$ 代入异中心神经场模型总输入并按相同时间索引推进神经场、解码速度和更新位置
  结束 对于
  进入下一个时间步
结束 对于
返回 $\{q_i(k)\}$、$\{u_i(k)\}$、$\{I_i(k)\}$

通过状态模型与输入模式的组合，可得到三种预测补偿方法：KF-mean 使用常角速度模型的预测均值方向核；KF-uncertainty 使用常角速度模型的协方差卷积方向核；KF-GM-uncertainty 使用阻尼角速度模型和协方差卷积方向核。fresh-drop 与 hold-last 作为实验基线，分别使用当前新鲜方位与最后一次观测方位，不需要执行上述 Kalman 递推。

4 预测不确定性与神经场输入的理论性质

间歇方位观测下的异中心神经场需要同时处理方向估计、预测不确定性和社会输入缺失。为刻画这些因素之间的关系，本章以方位后验、周期社会输入和神经场状态为理论对象，建立一条可检验的误差传播链：

$$\text{方位后验} \longrightarrow \text{社会输入误差} \longrightarrow \text{神经场状态误差} \longrightarrow \text{速度与位置偏差}.$$

理论分析包含四个相互衔接的层次：首先证明协方差感知输入在相同有效轨迹集合上的条件均方最优性，并量化只使用预测均值所产生的额外重建风险；其次区分完整邻居集合与有效轨迹集合，分解方向预测误差、漏邻居误差和错误关联误差；随后将连续缺失期间的方位方差传播转化为周期方向谐波衰减和方向信息保持窗口；最后在神经场推进映射满足局部 Lipschitz 条件时，给出社会输入扰动到神经场状态、速度解码和位置偏差的有限时间传播界。上述结论分别描述输入重建、方向信息保持和有限时间状态偏差，不将局部输入最优性等同于全局闭环稳定性。

4.1 理论对象、符号与适用条件

考虑智能体 i 在时刻 k 的观测历史 $\mathcal{Y}_i(k)$。记异中心神经场模型中的有向邻居集合为 $\mathcal{B}_i(k)$，由历史观测确定、已经初始化且尚未过期的有效轨迹集合为

$$\mathcal{S}_i(k) \subseteq \mathcal{B}_i(k).$$

前者表示参考社会输入包含的邻居，后者表示当前预测器维护的有效轨迹。协方差感知输入在 $\mathcal{S}_i(k)$ 上重建方向信息，集合差 $\mathcal{B}_i(k) \setminus \mathcal{S}_i(k)$ 对应遗漏输入。

对环形神经场的方向单元 α_m，定义周期方位核

$$g_\sigma(x) = \exp\left[-\frac{\operatorname{wrap}(x)^2}{2\sigma_s^2}\right], \qquad \operatorname{wrap}(x) = \operatorname{mod}(x+\pi, 2\pi) - \pi. \tag{55}$$

其中 $0 < \sigma_s \le \pi$。圆周距离记为

$$d_{\mathbb{S}^1}(a,b) = |\operatorname{wrap}(a-b)|. \tag{56}$$

对 $j \in \mathcal{B}_i(k)$，令 $\Theta_{ij}(k) \in \mathbb{S}^1$ 表示真实世界方位；对 $j \in \mathcal{S}_i(k)$，方位预测器给出预测均值 $\mu_{ij}(k)$ 和方位方差 $V_{ij}(k)$。在当前观测历史条件下，假定有效轨迹的方位边缘后验满足

$$\Theta_{ij} \mid \mathcal{Y}_i \sim \mathrm{WN}(\mu_{ij}, V_{ij}), \qquad j \in \mathcal{S}_i, \tag{57}$$

其中 WN 表示包裹正态分布。不同邻居之间不要求条件独立，因为本章的条件期望和误差分解只使用线性性与三角不等式。该假设还要求局部展开角分支在当前时间窗口内有效、邻居身份已经正确关联，且轨迹仍满足生命周期和有效性规则。

定义有效轨迹集合上的理想社会输入

$$J_{im}^{(\mathcal{S})} = h_0 \sum_{j \in \mathcal{S}_i} g_\sigma(\alpha_m - \Theta_{ij}), \qquad J_i^{(\mathcal{S})} = [J_{i0}^{(\mathcal{S})}, \dots, J_{i,M-1}^{(\mathcal{S})}]^\top. \tag{58}$$

完整邻居集合上的新鲜参考输入定义为

$$J_{im}^{(\mathcal{B})} = h_0 \sum_{j\in\mathcal{B}_i} g_\sigma(\alpha_m - \Theta_{ij}), \qquad J_i^{(\mathcal{B})} = [J_{i0}^{(\mathcal{B})}, \dots, J_{i,M-1}^{(\mathcal{B})}]^\top. \tag{59}$$

显然，$J_i^{(\mathcal{B})}$ 与 $J_i^{(\mathcal{S})}$ 只有在当前有效轨迹集合覆盖全部参考邻居时才一致。

令

$$\bar{g}_\sigma(x; V) = \int_{-\pi}^{\pi} g_\sigma(x-\epsilon) p_{\mathrm{WN}}(\epsilon; 0, V)\,\mathrm{d}\epsilon, \tag{60}$$

并定义协方差感知输入

$$\bar{J}_{im}^{(\mathcal{S})} = h_0 \sum_{j\in\mathcal{S}_i} \bar{g}_\sigma(\alpha_m - \mu_{ij}; V_{ij}), \qquad \bar{J}_i^{(\mathcal{S})} = [\bar{J}_{i0}^{(\mathcal{S})}, \dots, \bar{J}_{i,M-1}^{(\mathcal{S})}]^\top. \tag{61}$$

4.2 协方差感知输入的条件均方最优性

定理 4.1 (有效轨迹集合上的条件均方最优性)**.** *在式 (57) 的后验模型、相同有效轨迹集合 $\mathcal{S}_i$ 和给定观测历史 $\mathcal{Y}_i$ 下，式 (61) 满足*

$$\bar{J}_i^{(\mathcal{S})} = \mathbb{E}[J_i^{(\mathcal{S})} \mid \mathcal{Y}_i]. \tag{62}$$

因此，对任意仅依赖 $\mathcal{Y}_i$ 且具有有限二阶矩的输入估计 $\widetilde{J}_i$，有

$$\begin{aligned} \mathbb{E}[\|J_i^{(\mathcal{S})} - \widetilde{J}_i\|_2^2 \mid \mathcal{Y}_i] = \mathbb{E}[\|J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\|_2^2 \mid \mathcal{Y}_i] \\ + \|\bar{J}_i^{(\mathcal{S})} - \widetilde{J}_i\|_2^2. \end{aligned} \tag{63}$$

故协方差感知输入在该估计类中唯一地最小化有效轨迹集合上的理想社会输入条件均方重建误差，除去概率为零的等价情形。

证明. 对任意方向单元 α_m，由条件期望线性性和式 (57)，有

$$\begin{aligned} \mathbb{E}[J_{im}^{(\mathcal{S})} \mid \mathcal{Y}_i] &= h_0 \sum_{j\in\mathcal{S}_i} \mathbb{E}[g_\sigma(\alpha_m - \Theta_{ij}) \mid \mathcal{Y}_i] \\ &= h_0 \sum_{j\in\mathcal{S}_i} \bar{g}_\sigma(\alpha_m - \mu_{ij}; V_{ij}) = \bar{J}_{im}^{(\mathcal{S})}. \end{aligned} \tag{64}$$

逐分量成立即得式 (62)。再将误差分解为

$$J_i^{(\mathcal{S})} - \widetilde{J}_i = \big(J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\big) + \big(\bar{J}_i^{(\mathcal{S})} - \widetilde{J}_i\big). \tag{65}$$

第二项由 $\mathcal{Y}_i$ 确定，且第一项的条件均值为零，因此平方展开后的交叉项条件期望为零，得到式 (63)。 □

定理 4.1 不是 Kalman 滤波器递推本身的新最优性，而是一个针对异中心神经场输入接口的投影结论：当预测器提供方位后验时，把后验分布作用于方向核所得的输入，正是有效轨迹集合上理想社会输入的条件期望。因此，协方差不再只是滤波器内部的诊断量，而成为神经场输入构造的一部分。

4.3 均值输入的额外重建风险

KF-mean 只把预测均值代入方向核：

$$J_{im}^{\mathrm{mean}} = h_0 \sum_{j\in\mathcal{S}_i} g_\sigma(\alpha_m - \mu_{ij}). \tag{66}$$

推论 4.2 (忽略方位协方差的额外风险)**.** *在定理 4.1 的条件下，KF-mean 相对于协方差感知输入增加的条件均方重建风险为*

$$\mathbb{E}[\|J_i^{(\mathcal{S})} - J_i^{\mathrm{mean}}\|_2^2 \mid \mathcal{Y}_i] - \mathbb{E}[\|J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\|_2^2 \mid \mathcal{Y}_i] = \|\bar{J}_i^{(\mathcal{S})} - J_i^{\mathrm{mean}}\|_2^2 \geq 0. \tag{67}$$

当所有 $V_{ij} \to 0$ 时，$\bar{J}_i^{(\mathcal{S})}$ 与 J_i^{mean} 趋于一致；在非零方差下，二者一般不一致。

证明. 在式 (63) 中取 $\widetilde{J}_i = J_i^{\mathrm{mean}}$ 即得。 □

对 $0 < \sigma_s \leq \pi$，周期核关于圆周距离满足 Lipschitz 界

$$|g_\sigma(a) - g_\sigma(b)| \leq L_\sigma d_{\mathbb{S}^1}(a,b), \qquad L_\sigma = \frac{e^{-1/2}}{\sigma_s}. \tag{68}$$

在局部展开角分支有效且 $\mathbb{E}[d_{\mathbb{S}^1}(\mu_{ij},\Theta_{ij})^2 \mid \mathcal{Y}_i] \leq V_{ij}$ 时，有

$$\mathbb{E}[\|J_i^{\mathrm{mean}} - J_i^{(\mathcal{S})}\|_\infty \mid \mathcal{Y}_i] \leq h_0 L_\sigma \sum_{j\in\mathcal{S}_i} \sqrt{V_{ij}}. \tag{69}$$

该界不包含漏掉邻居或错误关联造成的误差，因而只描述已跟踪集合内的均值预测风险。

4.4 完整社会输入的误差分解

命题 4.3 (预测误差与漏邻居误差的分解)**.** *令 $\mathcal{S}_i \subseteq \mathcal{B}_i$，则有*

$$J_i^{(\mathcal{B})} - \bar{J}_i^{(\mathcal{S})} = \left(J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\right) + J_i^{(\mathcal{B}\setminus\mathcal{S})}. \tag{70}$$

进一步，在 $0 \leq g_\sigma \leq 1$ 时，满足

$$\|J_i^{(\mathcal{B})} - \bar{J}_i^{(\mathcal{S})}\|_\infty \leq \|J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\|_\infty + h_0|\mathcal{B}_i \setminus \mathcal{S}_i|. \tag{71}$$

若再满足式 (69) 的条件，则由条件 Jensen 不等式和三角不等式，

$$\begin{aligned} &\mathbb{E}[\|J_i^{(\mathcal{S})} - \bar{J}_i^{(\mathcal{S})}\|_\infty \mid \mathcal{Y}_i] \\ &\quad \leq 2\mathbb{E}[\|J_i^{(\mathcal{S})} - J_i^{\mathrm{mean}}\|_\infty \mid \mathcal{Y}_i] \leq 2h_0 L_\sigma \sum_{j\in\mathcal{S}_i} \sqrt{V_{ij}}. \end{aligned} \tag{72}$$

进而有

$$\mathbb{E}[\|J_i^{(\mathcal{B})} - \bar{J}_i^{(\mathcal{S})}\|_\infty \mid \mathcal{Y}_i] \leq h_0 \left(2L_\sigma \sum_{j\in\mathcal{S}_i} \sqrt{V_{ij}} + |\mathcal{B}_i \setminus \mathcal{S}_i|\right). \tag{73}$$

证明. 将式 (58) 和式 (59) 按集合 $\mathcal{S}_i$ 与 $\mathcal{B}_i \setminus \mathcal{S}_i$ 拆分即可得到式 (70)。由于 g_σ 与 $\bar{g}_\sigma$ 的值均不超过 1，遗漏集合对每一个方向单元的输入幅值不超过 $h_0|\mathcal{B}_i \setminus \mathcal{S}_i|$，再使用三角不等式得到式 (71)。另一方面，$\bar{J}_i^{(\mathcal{S})} = \mathbb{E}[J_i^{(\mathcal{S})} \mid \mathcal{Y}_i]$，故

$$\|J_i^{\mathrm{mean}} - \bar{J}_i^{(\mathcal{S})}\|_\infty \leq \mathbb{E}[\|J_i^{\mathrm{mean}} - J_i^{(\mathcal{S})}\|_\infty \mid \mathcal{Y}_i].$$

将其与三角不等式及式 (69) 结合，得到式 (72)；最后代入式 (71) 得到式 (73)。 □

命题 4.3 将输入误差分为有效轨迹内的方向预测误差和集合外的遗漏输入。协方差卷积作用于前者，其条件均方最优性建立在给定有效轨迹集合上；后者通过轨迹初始化、存在性判断和数据关联处理。

若需要描述错误数据关联，可另定义错误轨迹集合 $\mathcal{A}_i$，并将其输入作为第三项加入式 (70)。本章不对该项建立概率模型，只保留其作为模型适用边界。

4.5　方向谐波衰减与信息保持窗口

令原方向核的 Fourier 系数为

$$c_n = \frac{1}{2\pi}\int_{-\pi}^{\pi} g_\sigma(x) e^{-inx}\,\mathrm{d}x. \tag{74}$$

由于 wrapped normal 的第 n 阶特征函数为 $\exp(-n^2V/2)$，周期卷积核的系数为

$$c_n(V) = c_n \exp\left(-\frac{n^2 V}{2}\right). \tag{75}$$

因此一阶方向信息的保留比例为

$$\gamma_1(V) = \exp(-V/2). \tag{76}$$

在常角速度模型下，设最后一次观测更新后的协方差为

$$P_0 = \begin{bmatrix} p_{11} & p_{12} \\ p_{12} & p_{22} \end{bmatrix}. \tag{77}$$

连续缺失 $T = b\Delta t$ 后，方位预测方差为

$$V(T) = p_{11} + 2Tp_{12} + T^2 p_{22} + \frac{q_\omega T^3}{3}. \tag{78}$$

推论 4.4 (一阶方向信息保持窗口). 给定一阶方向信息的最低保留比例 $\gamma_{\min} \in (0,1)$，令

$$V_{\max} = -2\ln \gamma_{\min}. \tag{79}$$

则理论方向信息窗口定义为

$$T_\gamma = \sup\left\{T \ge 0 : V(s) \le V_{\max},\ \forall s \in [0,T]\right\}. \tag{80}$$

在 $[0, T_\gamma]$ 内有 $\gamma_1(s) \ge \gamma_{\min}$。当 $p_{12} < 0$ 时，$V(s)$ 在极短时间内可能不单调，因此必须检查整个区间而不能只检查终点。

证明. 由式 (76)，$\gamma_1(s) \ge \gamma_{\min}$ 当且仅当 $V(s) \le -2\ln\gamma_{\min} = V_{\max}$。对所有 $s \in [0,T]$ 同时要求该条件，即得到式 (80)。 □

若只需要单调的保守上界，可使用

$$\overline{V}(T) = p_{11} + 2T|p_{12}| + T^2 p_{22} + \frac{q_\omega T^3}{3}, \qquad V(T) \le \overline{V}(T), \tag{81}$$

并以 $\overline{V}(T) = V_{\max}$ 的最小正根定义保守窗口。该窗口是单条已跟踪邻居的方向信息窗口，不是集群稳定时间、碰撞安全时间或邻居存在时间。

4.6 神经场的有限时间输入—状态误差界

为刻画社会输入误差对神经场动力学的影响，定义神经场的无输入推进映射

$$f(u) = -u + \frac{1}{M} W \tanh(\beta u) - h_b \mathbf{1}, \qquad \Phi(u) = u + \Delta t f(u). \tag{82}$$

由于逐分量的 $\tanh(\beta u)$ 是 β-Lipschitz，推进映射在全空间上可取保守常数

$$L_\Phi^{\mathrm{glob}} = |1 - \Delta t| + \frac{\Delta t \beta}{M} \|W\|_2. \tag{83}$$

若已知两条轨迹均落在状态区域 $\mathcal{U}$，则还可以通过 Jacobian 得到更紧的局部常数

$$L_\Phi(\mathcal{U}) = \sup_{u \in \mathcal{U}} \left\| (1 - \Delta t) I_M + \frac{\Delta t \beta}{M} W \operatorname{diag}\big(\operatorname{sech}^2(\beta u)\big) \right\|_2. \tag{84}$$

全局常数适合给出无需轨迹信息的保守界；局部常数可利用神经元已经进入饱和区时 $\operatorname{sech}^2(\beta u)$ 较小的事实，但必须由给定状态区域或保存轨迹独立验证。考虑从同一检查点开始的两条轨迹：fresh 轨迹使用 $J_i^{(\mathcal{B})}$，预测轨迹使用 $\widehat{J}_i$。令

$$e_{u,i}(k) = u_i^{\mathrm{pred}}(k) - u_i^{\mathrm{fresh}}(k), \qquad \Delta I_i(k) = \widehat{J}_i(k) - J_i^{(\mathcal{B})}(k). \tag{85}$$

定理 4.5 (神经场状态的有限时间输入—状态误差界)**.** 设两条轨迹在区间 $k \in \{k_0, \dots, k_0 + H\}$ 内均落在状态区域 $\mathcal{U}$，且神经场推进映射满足

$$\|\Phi(u) - \Phi(v)\|_2 \le L_\Phi \|u - v\|_2, \qquad u, v \in \mathcal{U}. \tag{86}$$

则对任意 $\ell \in \{0, \dots, H\}$，有

$$\|e_{u,i}(k_0 + \ell)\|_2 \le L_\Phi^\ell \|e_{u,i}(k_0)\|_2 + \Delta t \sum_{r=0}^{\ell-1} L_\Phi^{\ell-1-r} \|\Delta I_i(k_0 + r)\|_2. \tag{87}$$

特别地，当两条轨迹从同一检查点分叉，即 $e_{u,i}(k_0) = 0$，状态偏差完全由输入误差传播项决定。若进一步有 $L_\Phi < 1$ 且 $\|\Delta I_i(k)\|_2 \le \varepsilon_I$，则

$$\|e_{u,i}(k_0 + \ell)\|_2 \le \frac{\Delta t (1 - L_\Phi^\ell)}{1 - L_\Phi} \varepsilon_I \le \frac{\Delta t}{1 - L_\Phi} \varepsilon_I. \tag{88}$$

证明. 由两条神经场递推式相减，得到

$$e_{u,i}(k+1) = \Phi(u_i^{\mathrm{pred}}(k)) - \Phi(u_i^{\mathrm{fresh}}(k)) + \Delta t \Delta I_i(k). \tag{89}$$

对上式应用式 (86) 和三角不等式，得到

$$\|e_{u,i}(k+1)\|_2 \le L_\Phi \|e_{u,i}(k)\|_2 + \Delta t \|\Delta I_i(k)\|_2. \tag{90}$$

反复递推即得式 (87)。当 $L_\Phi < 1$ 时，对等比和求和即可得到式 (88)。 □

条件 (86) 在给定局部状态区域内成立。一般情况下采用有限时间界 (87)；当该区域内的局部收缩条件 $L_\Phi < 1$ 得到验证时，可进一步使用有界式 (88)。

将命题 4.3 代入定理 4.5，可得遮挡期间神经场状态偏差由已跟踪邻居的方向预测误差和遗漏邻居的输入缺口共同决定。该分解将方向预测与邻居存在性管理的作用分别纳入误差传播分析。

4.7 速度解码与位置偏差的有限时间界

神经场输出的正活动为

$$a_{im}=\max\{\tanh(\beta u_{im}),0\},\qquad c_i=\sum_{m=0}^{M-1}a_{im}e^{\mathrm{i}\alpha_m},\qquad v_i=v_s[\Re c_i,\Im c_i]^{\top}. \tag{91}$$

引理 4.6 (神经场状态到速度的 Lipschitz 界)**.** 对任意两个神经场状态 u 和 v，有

$$\|v(u)-v(v)\|_2\le v_s\beta\sqrt{M}\|u-v\|_2. \tag{92}$$

证明. 函数 $x\mapsto\max\{\tanh(\beta x),0\}$ 是 β-Lipschitz，因此正活动向量满足 $\|a(u)-a(v)\|_2\le\beta\|u-v\|_2$。复数合矢量是 M 个单位模方向向量的线性组合，故 $\|c(u)-c(v)\|_2\le\sqrt{M}\|a(u)-a(v)\|_2$。乘以速度尺度 v_s 即得式 (92)。 □

令 $d_{\mathbb{T}^2}$ 表示二维周期区域上的最小镜像距离。由于周期取模映射在该距离下不扩张，两条轨迹满足

$$d_{\mathbb{T}^2}(q_i^{\mathrm{pred}}(k+1),q_i^{\mathrm{fresh}}(k+1))\le d_{\mathbb{T}^2}(q_i^{\mathrm{pred}}(k),q_i^{\mathrm{fresh}}(k))+\Delta t\|v_i^{\mathrm{pred}}(k)-v_i^{\mathrm{fresh}}(k)\|_2. \tag{93}$$

结合引理 4.6 和定理 4.5，从同一检查点开始的有限时间位置偏差满足

$$\begin{aligned}d_{\mathbb{T}^2}(q_i^{\mathrm{pred}}(k_0+\ell),q_i^{\mathrm{fresh}}(k_0+\ell))&\le v_s\beta\sqrt{M}\Delta t\\&\quad\times\sum_{r=0}^{\ell-1}\|e_{u,i}(k_0+r)\|_2.\end{aligned} \tag{94}$$

该式是个体有限时间位置偏差界，不是集群 GO、LO 或碰撞概率的直接上界。后者还需要对速度归一化、个体间耦合和危险距离阈值增加额外假设，因此本章不将式 (94) 扩展为闭环安全定理。

4.8 三类条件有效窗口

为避免把单一方向指标误称为集群稳定时间，本章区分三类窗口。

定义 4.7 (方向信息窗口)**.** 给定 $\gamma_{\min}$，式 (80) 定义的一阶谐波保留窗口称为方向信息窗口 T_γ。

定义 4.8 (社会输入误差窗口)**.** 给定输入容许误差 ε_I，定义

$$T_I(\varepsilon_I)=\sup\left\{T\ge0:\sup_{0\le s\le T}\mathcal{E}_I(s)\le\varepsilon_I\right\}, \tag{95}$$

其中 $\mathcal{E}_I(s)$ 可以取式 (73) 右侧的条件期望上界，或由校准后的预测误差模型给出。

定义 4.9 (神经场状态窗口)**.** 给定神经场状态容许误差 ε_u，定义

$$T_u(\varepsilon_u)=\sup\left\{T\ge0:\sup_{0\le s\le T}\mathcal{E}_u(s)\le\varepsilon_u\right\}, \tag{96}$$

其中 $\mathcal{E}_u(s)$ 由式 (87) 计算。

实际预测器的可用窗口还受到轨迹年龄截止和方位方差截止约束。因此可定义条件可用窗口

$$T_{\mathrm{usable}}=\min\left\{T_\gamma,T_I(\varepsilon_I),T_u(\varepsilon_u),\tau_{\max}\right\}. \tag{97}$$

式 (97) 不是普适的遮挡阈值，而是依赖 N、神经场参数、输入制度、有效轨迹集合、q_ω、R、初始协方差和误差容许值的条件函数。它的作用是把算法中的 $\tau_{\max}$ 和 $P_{11,\max}$ 与理论误差尺度联系起来，而不是替代独立的闭环实验。

4.9 理论结果的验证方式与适用条件

本章理论至少需要通过以下三类检查验证。第一，在已保存方位轨迹上比较实测方位误差、$V(T)$ 和 $\gamma_1(T)$，检查理论趋势是否成立。第二，在相同观测历史下计算 KF-mean 与 KF-uncertainty 的社会输入均方误差，检查式 (67) 给出的风险差方向。第三，在完整检查点分叉实验中记录神经场状态差、速度差和位置差，检查式 (87) 是否成为保守但有效的上界。

上述分析采用局部连续的单峰 wrapped normal 方位后验，并在给定有效轨迹集合上讨论条件均方输入重建。一阶方向信息窗口刻画周期输入的方向集中度；有限时间神经场界依赖局部 Lipschitz 条件，位置界比较同一检查点分叉后的个体轨迹。实验分别评价协方差覆盖率、输入重建和群体响应，以连接这些理论量与实际运动表现。

4.10 本章理论贡献总结

本章的理论贡献可以概括为四个层次。第一，在给定 wrapped normal 方位后验和相同有效轨迹集合的条件下，证明协方差感知周期卷积输入是理想社会输入的条件均方最优估计，并量化 KF-mean 忽略协方差造成的额外重建风险。第二，将连续缺失期间的方位方差传播转化为周期方向谐波衰减，定义可计算的一阶方向信息窗口。第三，区分有效轨迹内的预测误差与完整邻居集合相对于有效轨迹集合的输入缺口，给出完整社会输入误差的可计算分解。第四，在局部 Lipschitz 条件下给出社会输入误差到神经场状态、速度解码和有限时间位置偏差的传播界，建立从方位预测后验、输入重建到有限时间运动偏差的理论链条。

本章建立了仅方位预测后验到异中心环形神经场输入及其有限时间扰动传播的理论接口。相应的实验评价包括方位误差与理论方差的关系、有效轨迹集合上的输入重建误差、遗漏输入的作用，以及受控转向过程中的群体相对退化。

5 仿真实验与结果

5.1 实验设置

仿真采用 $N = 20$、$M = 100$、$\Delta t = 0.3$、$v_s = 0.05$、$\beta = 1000$ 和 $\sigma_s = 0.4$，周期方形区域边长 $L = 1000$。闭环补偿实验采用完整检查点分叉：无遮挡控制和全部遮挡分支从同一位置、航向、神经活动、神经元偏好方向、固定邻居身份及预生成观测噪声流开始。扩展遮挡时长实验取固定循环有向邻居边数 $n_e = 15$；第 5.5 节的五种子机制实验取 $n_e = 8$，各批次按自身协议分别统计。

表 2 中，T 为连续遮挡时长，q_ω 为角加速度噪声谱强度，τ 为阻尼模型相关时间，R 为方位测量方差，P_0 为初始化协方差，$\tau_{\max}$ 为观测年龄上限，$P_{11,\max}$ 为方位方差轨迹截止阈值。各批次分别统计：社会输入机制图使用种子 1–100 的独立机制扫描；预测校准诊断使用种子 138–139 进行参数选择、140–141 进行开发评估；方位预测与输入重建实验使用开发种子 1–5；无受控转向的扩展闭环实验和受控转向实验均使用种子 201–230，其中受控转向结果为完整的 30 个种子、2700 条配对闭环记录。主流模型比较仅作为不同传感信息条件下的辅助参考，不与仅方位闭环结果合并统计。

扩展遮挡时长实验比较五种方法：*fresh-drop* 在缺失时删除外部方位输入；*hold-last* 保持最后一次观测方位；*KF-mean* 使用常角速度 Kalman 预测均值；*KF-uncertainty* 使用常角速度 Kalman 均值和协方差卷积；*KF-GM-uncertainty* 使用阻尼角速度 Kalman 模型和协方差卷积。后文分别将 KF-uncertainty 和 KF-GM-uncertainty 简称为 KF-unc 和 KF-GM。所有方法均保留神经场内部状态；fresh-drop 删除的是外部方位输入。该批次每种条件包含 30 个种子，共 2700 条配对闭

表 2: 扩展配对闭环实验参数

参数	设置
个体数、神经元数	$N = 20$，$M = 100$
时间步长、速度尺度	$\Delta t = 0.3$，$v_s = 0.05$
神经参数	$\beta = 1000$，$\sigma_s = 0.4$，$L = 1000$
固定邻居边数	$n_e = 15$
隐藏边数	7/15、11/15、13/15
连续遮挡时长	$T = \{3, 6, 10.2, 18, 30, 60\}$
独立随机种子	201–230
测量噪声标准差	0.01 rad
常角速度 KF	$q_\omega = 10^{-4}$，$R = 10^{-4}$
阻尼角速度 KF	$q_\omega = 10^{-5}$，$\tau = 10$，$R = 10^{-4}$
滤波初始化	$P_0 = \mathrm{diag}(R, 1)$
轨迹截止	$\tau_{\max} = 120$，$P_{11,\max} = 1\ \mathrm{rad}^2$
评价窗口	遮挡期；遮挡后前 100 步；恢复仿真 300 步
受控转向设置	3 个领航个体；遮挡前 20 步开始转向；转向角速度 0.025 rad/模型时间
相对退化指标	相对无遮挡控制的 GO、LO 和凝聚距离绝对偏差

环结果。另设种子 1–5 的 KF 输入重建机制实验，使用删除、幅值归一化、方位保持和均值外推对照，形成 155 条唯一闭环轨迹，详细设置见第 5.5 节。

5.2 社会输入经验模型的验证结果

围绕第 2.3 节的指数方位加权公式，三个实验依次检验数量与强度的累加、固定总幅值下的方位差异，以及随机输入下的神经场响应解释能力。前两项为受控数值验证，第三项为按随机几何分组的探索性响应分析。

共用设置与评价指标。三个实验均采用单体局部神经场回放，固定异中心神经网格 $\alpha_m = 2\pi m/M$，取 $M = 100$、$\Delta t = 0.3$、$\sigma_s = 0.4$、$\beta = 1000$、连接指数 $\zeta = 0.5$、全局抑制 $h_b = 0$ 和速度尺度 $v_s = 0.05$。每例从零神经状态开始运行 120 步，输入方位和强度固定，无观测噪声、无遮挡，$\kappa = 1$。为在相同参考轴下比较不同输入，局部实验以初始自身朝向 $\phi_{i,0}$ 计算 S_i 和纵向响应；式 (22) 在时变轨迹中则使用当前朝向。定义末 20 步的平均纵向解码速度及其归一化量

$$Y_i = \frac{1}{20}\sum_{t=101}^{120} e_{i,0}^{\top} v_i(t), \qquad y_i = \frac{Y_i}{v_s M} = \frac{Y_i}{5}. \tag{98}$$

y_i 表示神经场输出沿初始朝向的运动分量，正、负值分别对应向前和向后响应；$S_i \geq 0$ 表示方位加权后的输入量。两者分别描述输入与输出。三个实验共形成 $16 + 27 + 240 = 283$ 条条件记录，其中一项条件共用回放，共计 282 次不同条件回放和 33840 次神经场更新。

5.2.1 实验一：数量与强度的累加关系

实验条件与基准。所有邻居均位于正前方，取 $\phi_{i,0} = 0$、$\theta_{ij} = 0$。邻居数 $n_i \in \{2, 4, 8, 12\}$，等权单边强度 $w \in \{0.006, 0.012, 0.024\}$，得到 12 例；另在四个邻居数下固定 $A_i = 0.228$、取 $w = A_i/n_i$，得到 4 例。以逐邻居叠加的完整高斯输入场为基准，检验 $S_i = n_i w$ 和固定总幅值下的响应一致性。

结果与分析。图 1a、b 中，S_i 随邻居数和单邻居强度线性增加，与解析关系 $S_i = n_i w$ 一致。固定总幅值 $A_i = 0.228$ 时，四种邻居数产生相同的输入场、神经状态和解码响应（图 1c），末段归一化响应均为 0.3182。这说明在方位重合且总幅值相同时，邻居数的作用已由求和中的强度累加体现。图 1d 显示首步响应随输入增加，由 0.2209 增至 0.3033；末段响应在本次强度范围内均趋于 0.3182。因此，输入的线性累加对应神经场中的非线性响应和饱和过程。

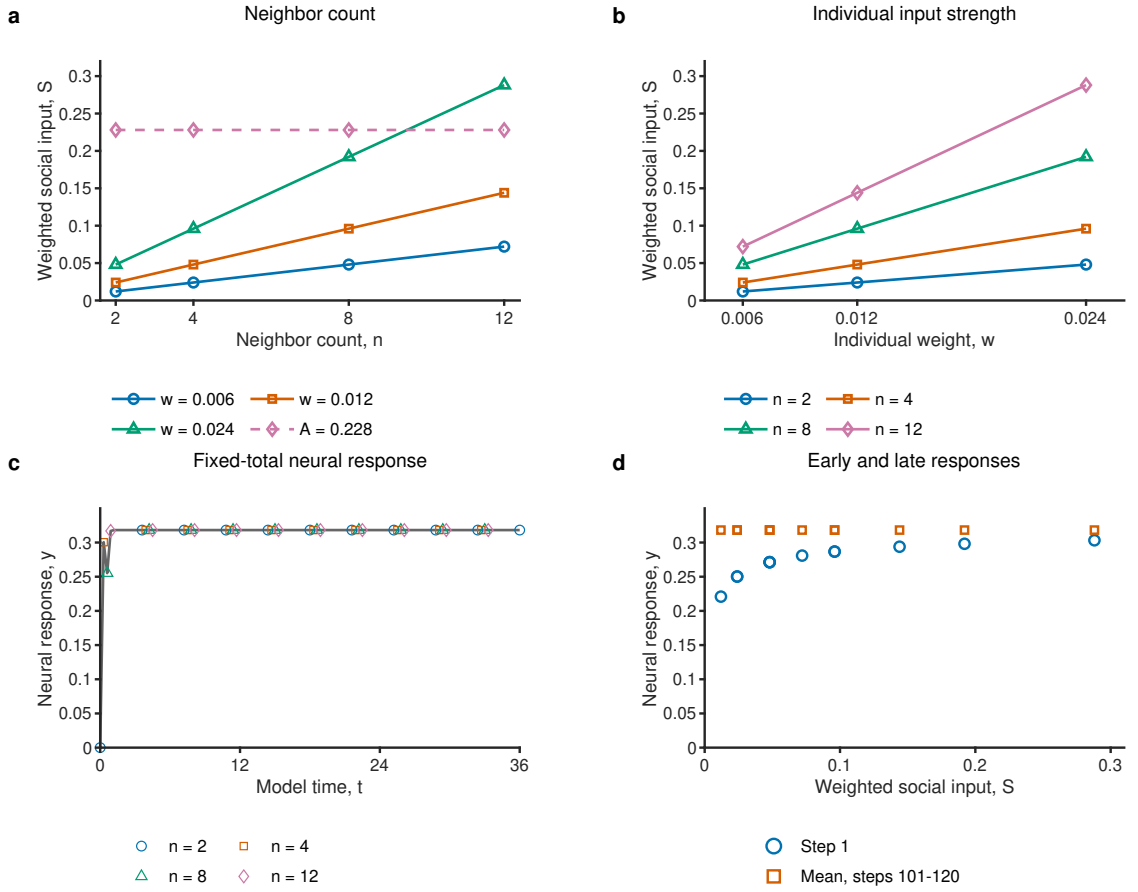


图 1: 正前方输入下的数量与强度累加关系。（a）三种单邻居强度及固定总幅值条件下的 S_i–n_i 关系；（b）四种邻居数下的 S_i–w 关系；（c）固定 $A_i = 0.228$ 时重合的归一化纵向响应，灰线表示共同轨迹，彩色标记在不同时间点采样以便辨识；（d）首步与末 20 步平均响应。纵向响应均除以 $v_s M = 5$，时间轴为模型时间。共 16 个确定性条件，$\kappa = 1$。

5.2.2　实验二：固定总幅值下的方位加权关系

实验条件与基准。固定 $n_i = 8$、$w = 0.0285$、$A_i = 0.228$、$\phi_{i,0} = 0$。所有邻居取相同方位，从 $-180°$ 到 $165°$、间隔 $15°$ 扫描，共 24 例；另加入前后双峰（各 4 个邻居位于 0、π）、左右双峰（各 4 个位于 $\pm\pi/2$）和圆周均匀（$2\pi j/8$，$j = 0, \ldots, 7$）三个模板，共 27 例。总幅值基准 A_i 在全部条件下相同，指数模型的解析对照为 $C_i = \exp(\cos\theta - 1)$。

结果与分析。图 2a 的重算值与解析曲线一致，正前、正侧和正后方的 C_i 分别为 1、0.3679 和 0.1353，对应 $S_i = 0.2280$、0.08388 和 0.03086。三个多峰模板具有不同的完整输入场（图 2b），前后双峰、左右双峰和均匀方位结构的 C_i 分别为 0.5677、0.3679 和 0.4658（图 2c）。总幅值保持

相同时，方位结构仍能改变加权输入；C_i 因而提供了幅值之外的结构描述。角度扫描的纵向输出随输入方位改变符号（图 2d），而指数输入量保持非负。图中标出的对称侧向条件具有数值敏感性，反映了对称输入下的方向解码特征。

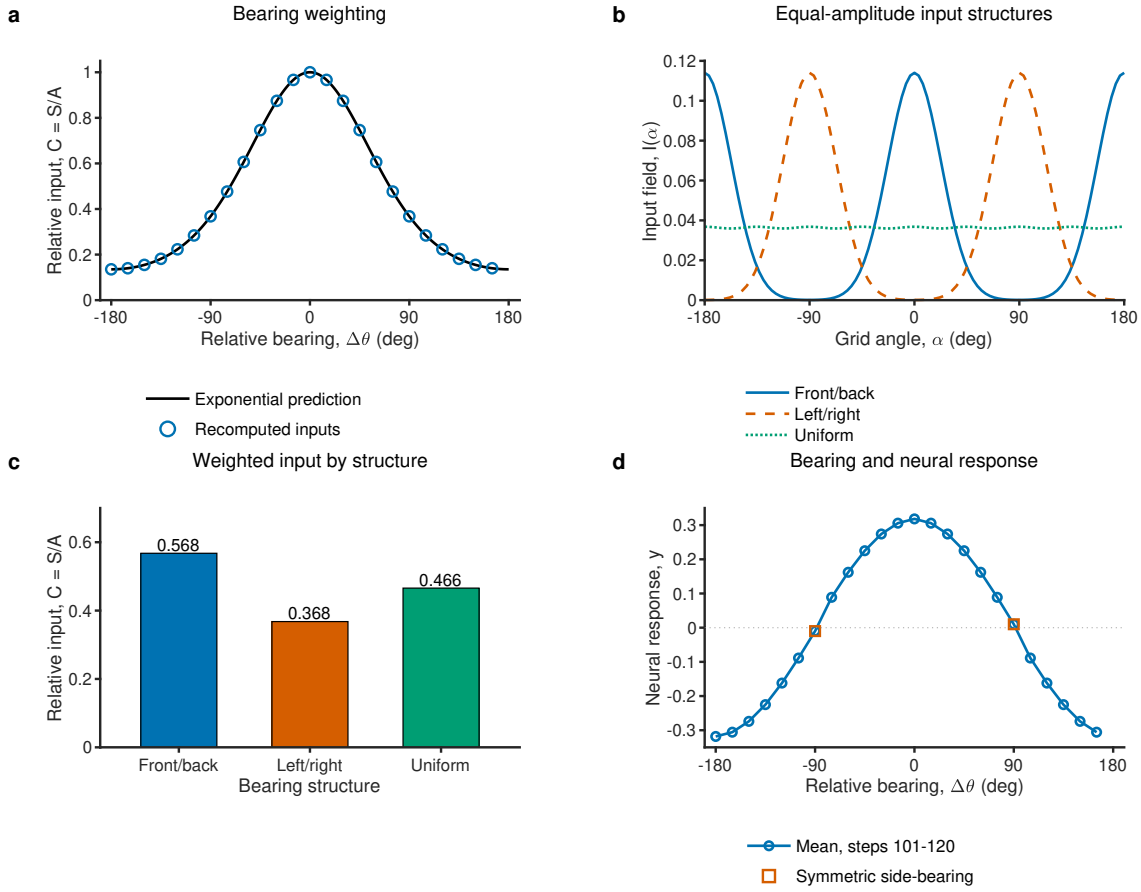


图 2: 固定邻居数与总幅值下的方位权重和输入结构。$n_i = 8$、$A_i = 0.228$、等权输入、$\kappa = 1$。（a）间隔 15° 的方位扫描重算值与 $\exp(\cos\Delta\theta - 1)$；（b）前后双峰、左右双峰与均匀方位的完整高斯输入场；（c）三个模板的 $C_i = S_i/A_i$；（d）方位扫描的末 20 步平均纵向响应 y_i，标记突出 $\pm 90°$ 对称侧向条件。角度轴具有周期性。共 27 个条件全部保留；对称侧向输出用于观察数值敏感性。

5.2.3 实验三：随机输入下的神经场响应对照

实验条件。取 $n_i \in \{2, 4, 8, 12\}$、$A_i \in \{0.114, 0.228, 0.456\}$ 和 20 组随机几何输入，共 240 例。每组使用 MATLAB 的 `mt19937ar` 随机流，种子为 20261011–20261030，按顺序生成 12 个 Uniform$(-\pi, \pi)$ 方位、12 个 Uniform$(0.5, 1.5)$ 原始权重和 1 个 Uniform$(-\pi, \pi)$ 初始自身朝向。各邻居数取前 n_i 个目标，将权重归一化到给定 A_i；同一种子的 12 个条件共用方位、原始权重和初始朝向。

基准与统计方法。分别以 $X_i = A_i$ 和 $X_i = S_i$ 建立带截距的一元线性回归 $Y_i = a + bX_i$，采用按几何种子分组的留一组交叉验证。每轮整体留出同一种子的 12 例测试，其余 228 例训练，$\kappa = 1$ 固定。以全部留出预测的归一化 RMSE 衡量响应预测误差，以每个几何种子的归一化 MSE 作配对比较。使用 5000 次成对几何组 bootstrap，报告百分位 95% 区间，随机流为 NumPy PCG64、

种子 2026101101；重采样单位为 20 个几何组，区间基于已拟合的留出误差。描述性的分层相关采用预先固定的方向判据：解码方向向量模大于 10^{-9} 时方向有效，否则将该步运动向量记为零。

结果与分析。图 3a 显示，相同总幅值下仍存在不同的输入加权量与纵向响应。加入方位权重后，归一化测试 RMSE 从幅值基准的 0.2060 降至 0.1729，相对降低 16.1%（图 3b、d；表 3）。20 个几何组中有 18 个的测试 MSE 更低（图 3c）。配对归一化 MSE 降低量 $\mathrm{MSE}_A - \mathrm{MSE}_S$ 的均值为 0.01257，95% bootstrap 区间为 [0.00835, 0.01687]。在具有响应变化的 10 个 (n_i, A_i) 分层中，S_i 与 y_i 的 Spearman 相关系数为 0.599–0.920；另外两个低幅值分层的输出为零，相关系数未定义。结果表明，指数方位加权在总幅值之外提供了与局部神经运动响应相关的信息。

表 3: 随机几何分组交叉验证的归一化响应误差。两种模型使用相同的单变量线性回归及分组划分，共 20 个几何组、240 个配对条件。区间由几何组 bootstrap 得到。

模型输入	测试 RMSE	95% bootstrap 区间
总幅值 A_i	0.2060	[0.1789, 0.2319]
指数加权输入 S_i	0.1729	[0.1515, 0.1937]

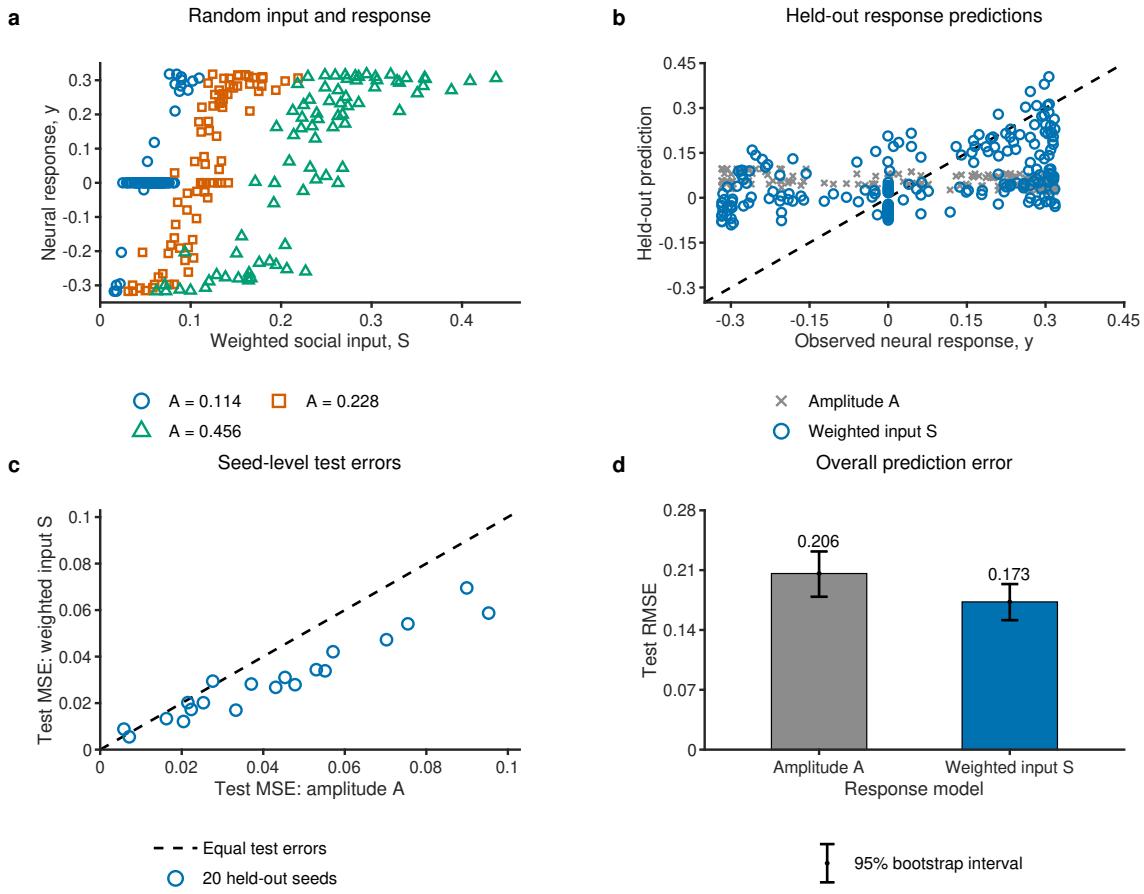


图 3: 随机几何输入下的留出响应预测。20 组几何各含 12 个数量–幅值条件，共 240 例。（a）S_i 与归一化响应 $y_i = Y_i/5$，按总幅值分组；（b）总幅值模型和指数加权模型的留出预测，虚线为预测与观测相等；（c）各几何组的测试 MSE，虚线下方表示指数加权模型误差较小，共 18/20 组；（d）全部留出预测的 RMSE。每折整体留出一个几何种子；误差棒为对已拟合留出误差进行 5000 次配对几何组 bootstrap 的 95% 百分位区间。

5.3 社会输入机制的基准影响

图 4 同时给出输入幅值、角度覆盖、输入集中度、GO、LO 和凝聚距离。随机选邻并采用模型原定单邻居幅值时，增加 n_e 会同时提高输入幅值和方向采样密度，使 GO、LO 上升并减小凝聚距离。固定总幅值后，输入幅值基本保持不变，但角度覆盖和输入集中度仍随选邻策略变化，反映了方向采样的作用。该结果支持将输入幅值和方位结构作为两个相互耦合且可区分的因素，并分别评价其对群体运动的影响。

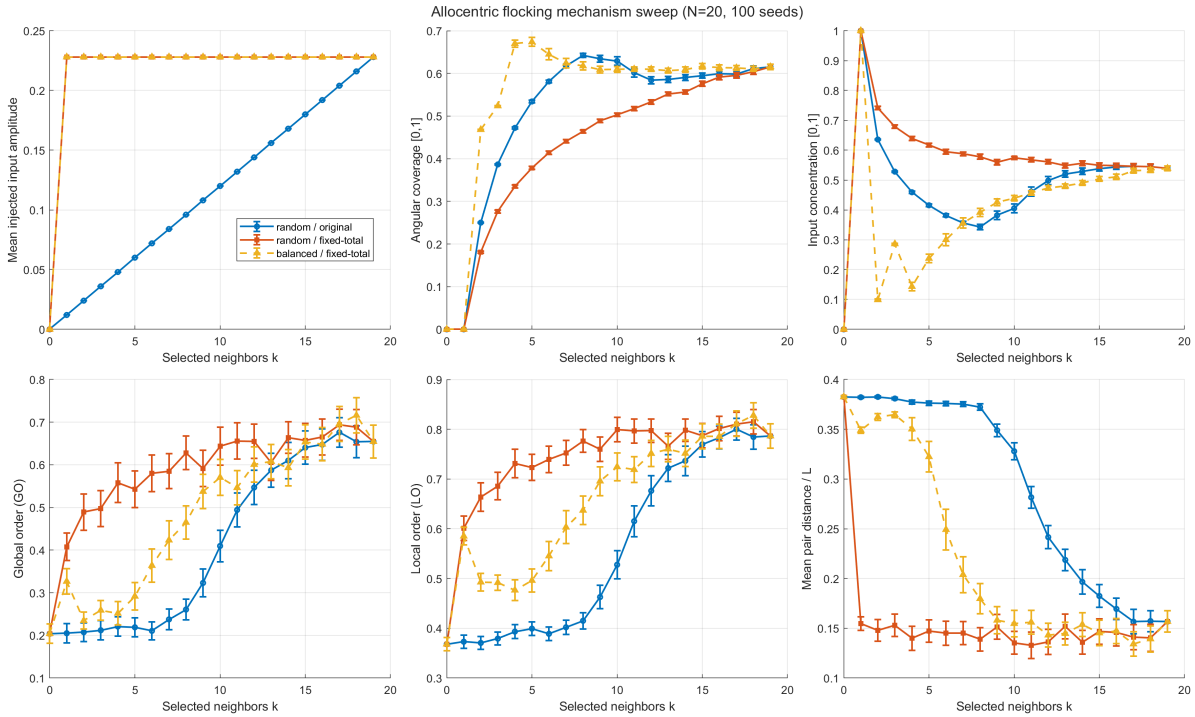


图 4: 邻居数量、输入幅值和方位选择策略的机制分解（N=20，种子 1–100）。

5.4 连续缺失下的协方差与方位预测

连续缺失期间，常角速度模型的方位协方差按

$$V(T) = p_{11} + 2Tp_{12} + T^2p_{22} + q_\omega T^3/3 \tag{99}$$

增长。周期卷积对第 n 阶方向谐波的衰减为 $\exp(-n^2V/2)$，随缺失时间增加展宽方向核并抑制高阶方向结构，同时保留总输入。图 5 的上排给出该解析性质，下排给出离线预测误差和 95% 经验覆盖率。较长遮挡下的覆盖率明显低于名义值，表明协方差低估了实际误差，后续需要按经验覆盖率校准。当前闭环改善主要体现为展宽方向核后对过期方向输入的抑制。

图 6 进一步给出隐藏边上的平均方位预测误差。相较 hold-last，阻尼角速度 KF-GM-uncertainty 在 $T \geq 6$ 时将预测误差降低约 13%–19%，配对 bootstrap 区间不跨零；在 $T = 60$ 时仍降低约 9%–10%。$T = 3$ 时均值降低约 11%–13%，但在两种较强遮挡条件下区间略跨零，因此只视为方向一致的短期改善。常角速度 KF 在短时遮挡中与 hold-last 接近，在中等和长时间缺失中才逐渐表现出均值预测优势。

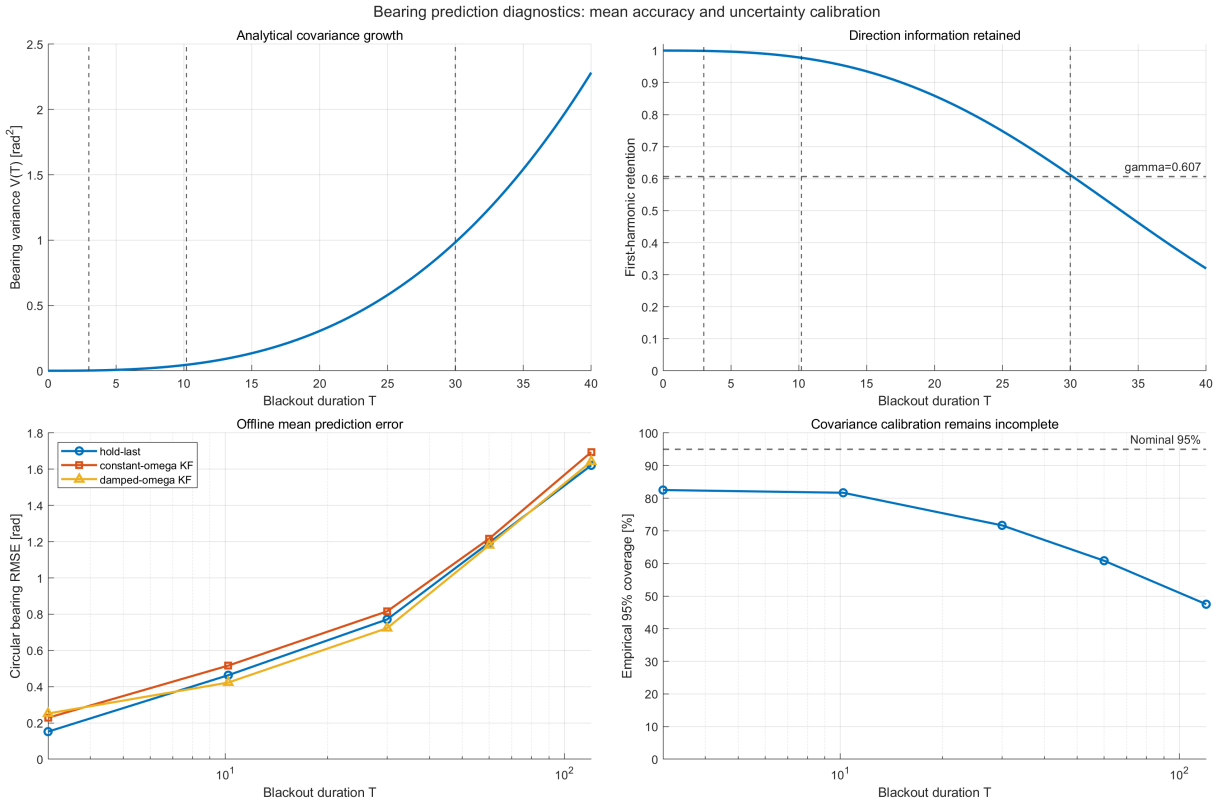


图 5: 方位预测诊断。上排为解析协方差与方向信息保持；下排为离线均值误差和 95% 经验覆盖率（种子 138–141）。

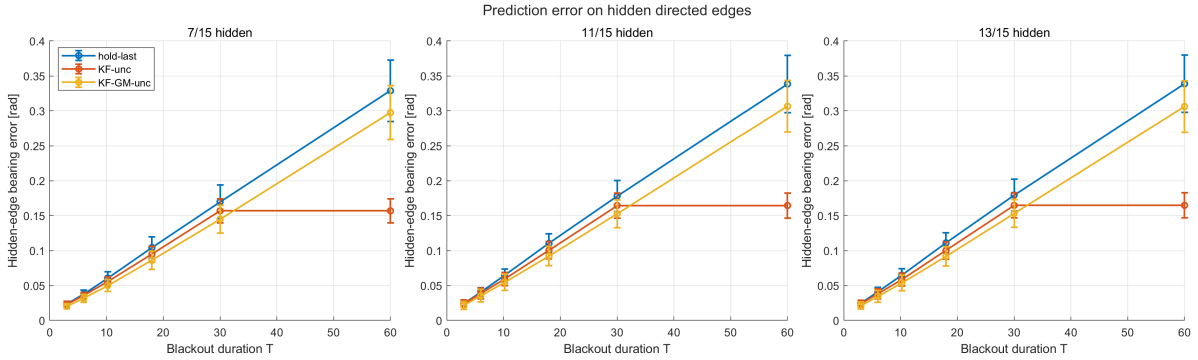


图 6: 隐藏有向边上的方位预测误差。误差仅用于诊断，不进入控制器。

5.5 方位预测与输入重建的分层机制实验

本节以离线方位预测、同状态输入重建和检查点分叉闭环三个层次，检验历史方位预测如何转化为神经场输入，并观察输入变化对应的群体运动响应。采用五个开发种子 1–5，以逐种子配对结果描述不同补偿策略的作用。

5.5.1 实验条件与对照方法

每个智能体固定选择编号向后的 8 个循环邻居，等权输入，总权重记为 A_0。完整观测运行至第 6200 步，在最后合法观测上冻结隐藏邻居身份；第 6201–6234 步屏蔽方位，共 34 步，即 10.2 个模型时间单位，第 6235 步恢复，仿真运行至第 6600 步。观测无噪声，方位采用世界坐标系，输入强度保持最后合法值。KF 采用常角速度状态，$q_\omega = 10^{-6}$、$R = 10^{-4}$、$P_0 = \mathrm{diag}(R, 1)$，初始角速度为零。此处 R 为固定的假定观测方差与数值正则量；协方差通过覆盖率和恢复首步 NIS 诊断。

围绕中心条件 $h = 4$、random、$A_0 = 0.228$，分别扫描隐藏邻居数 $h \in \{2, 4, 6\}$、隐藏方位结构 random/concentrated/dispersed，以及 $A_0 \in \{0.114, 0.228, 0.456\}$，共 7 个唯一条件。concentrated 和 dispersed 在最后合法观测上分别选择一阶圆周合矢量模 $R_1^{\mathcal{H}} = |h^{-1} \sum_{j \in \mathcal{H}_i} e^{\mathrm{i}\theta_{ij}}|$ 最大和最小的隐藏集合。每个 A_0 均重新运行完整前缀，同一 (seed, A_0) 内各方法共享检查点；幅值扫描因而同时包含预热动力学的变化。

对照包括：fresh 始终使用完整当前观测；drop 删除缺失边；drop-normalized 将可见边权重调整为 $A_0/(8-h)$，保持总幅值；hold 保持缺失边的最后方位及权重；KF-mean 按式 (47) 注入预测均值。drop 对应幅值与方位同时减少，drop-normalized 保留幅值而减少方位覆盖，hold 延续历史方位，KF-mean 在相同缓存权重上增加方向外推。恢复首步各方法均使用当前合法观测。新批次评估均值外推及协方差诊断，协方差卷积的闭环结果在后续扩展时长实验中分别报告。

每个种子有 3 条 fresh 参考轨迹和 $7 \times 4 = 28$ 条非 fresh 轨迹，五个种子共 155 条唯一闭环轨迹；同一 fresh 轨迹在对应条件中重复引用。另有 35 组同状态输入回放，以及 $7 \times 5 \times 3 = 105$ 项离线 R 诊断，其中替代 $R = 10^{-6}, 10^{-2}$ 均使用相同的完整 6200 步合法历史。统计按种子配对，采用 5000 次种子组 bootstrap，随机种子为 20261010，所有条件共用重采样索引。

5.5.2 评价指标与解释

离线层在 fresh 轨迹上屏蔽固定邻居观测，以缺失期间全部隐藏边–时间点的圆周误差计算每个种子的方位 RMSE，再对五个种子取均值。覆盖率为 $|e_{ij}| \le 1.96\sqrt{P^-_{11,ij}}$ 的边–时间点比例；归一化创新平方（NIS）为恢复首步的 $\nu_{ij}^2/(P^-_{11,ij} + R)$，在隐藏边上取均值，用于比较预测创新与假定方差。同状态层让各候选输入读取相同 fresh 状态，比较完整神经场输入向量，定义

$$E_I^{(s)} = \frac{1}{N|\mathcal{K}_o|} \sum_{k \in \mathcal{K}_o} \sum_{i=1}^{N} \frac{\|I_i^{(s)}(k) - I_i^{\mathrm{fresh}}(k)\|_2}{\|I_i^{\mathrm{fresh}}(k)\|_2}. \tag{100}$$

该误差直接描述在相同几何状态下输入场的重建程度；第 2.3 节的 S_i 则描述方位加权后的标量输入量。

闭环层在共同检查点上分别推进，主响应为恢复后 100 步，即 $\mathcal{K}_r = \{6235, \ldots, 6334\}$ 内的有符号平均对距变化

$$\Delta D^{(s)} = \frac{1}{|\mathcal{K}_r|} \sum_{k \in \mathcal{K}_r} \frac{d^{(s)}(k) - d^{\mathrm{fresh}}(k)}{L}, \quad D^{(s)}_{\mathrm{abs}} = \frac{1}{|\mathcal{K}_r|} \sum_{k \in \mathcal{K}_r} \frac{|d^{(s)}(k) - d^{\mathrm{fresh}}(k)|}{L}, \tag{101}$$

其中 d 为周期最短两两距离均值。ΔD 的正、负值分别表示相对 fresh 更分散、更紧凑，D_{abs} 补充描述偏离大小。GO 和 LO 的损失定义为相同窗口内 fresh 减去候选分支的时间平均值。

5.5.3 方位预测及协方差诊断结果

中心条件下，KF-mean 的逐种子 RMSE 均值为 0.1040 rad，hold 为 0.1414 rad，降低 26.4%，五个种子中四个误差更低。种子 2 的 KF 误差为 0.3757 rad，高于 hold 的 0.2348 rad，体现了常角速度外推对具体轨迹的敏感性。图 7a–c 中，隐藏数量从 2 增至 6 时，KF 均值误差从 0.1012 增至 0.1148 rad；集中与分散结构下分别为 0.0976 和 0.1396 rad。低幅值 $A_0 = 0.114$ 时 KF 为 0.2229 rad，高于 hold 的 0.2002 rad；$A_0 = 0.456$ 时 KF 降至 0.000481 rad。这些变化反映了不同输入条件及其预热轨迹下的预测表现。

主 R 下，中心条件的名义 95% 区间经验覆盖率为 89.76%，种子范围为 65.74%–100%，恢复首步平均 NIS 为 76.45。图 7d 显示不同假定 R 下覆盖率的种子差异，种子 2 的低覆盖率与其较大预测误差相对应。由此，预测均值改善与协方差校准需要分别评价，后续将以经验覆盖率校准不确定性传播。

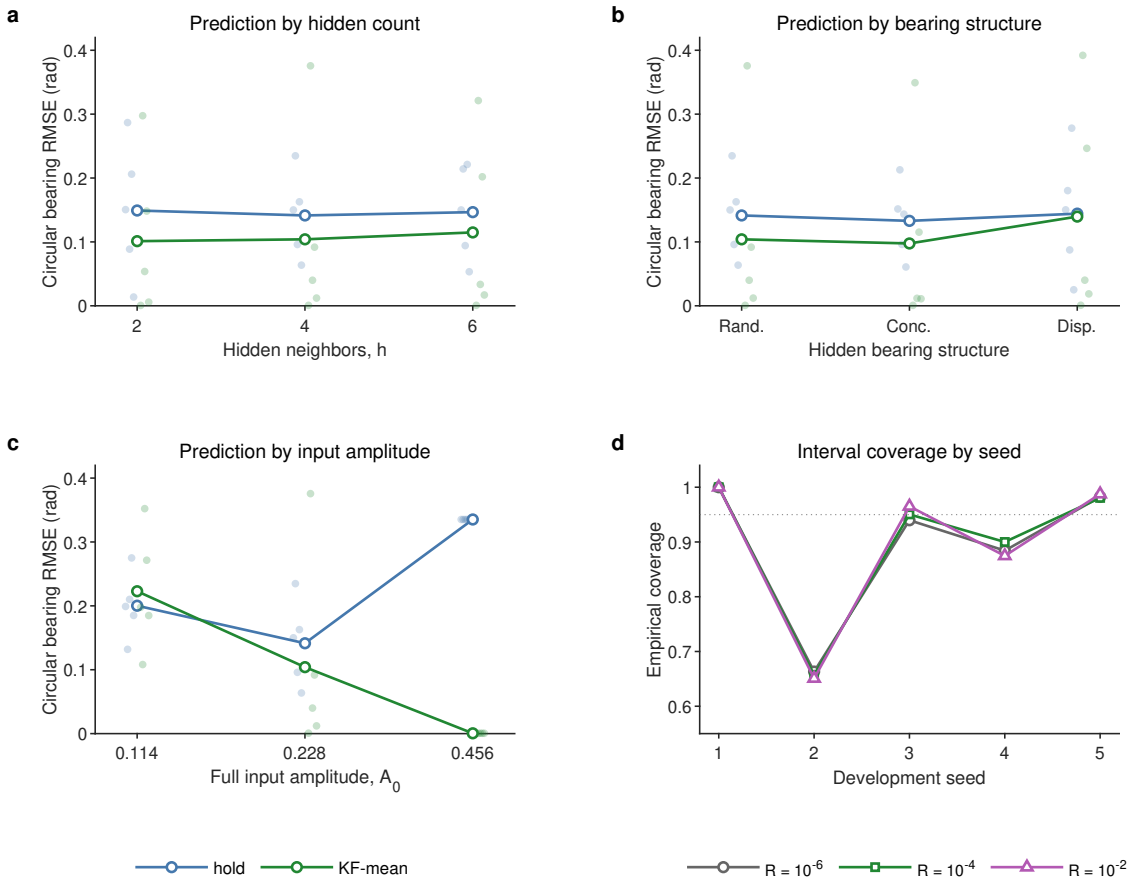


图 7: 五种子开发实验中的方位预测与覆盖率诊断。（a–c）分别扫描隐藏邻居数、隐藏方位结构和完整观测总幅值；连线点为五个逐种子圆周 RMSE 的均值，浅色散点为各种子值，主 $R = 10^{-4}$。三个扫描共享中心条件 $h = 4$、random、$A_0 = 0.228$。（d）中心条件下三个假定 R 的逐种子经验覆盖率，虚线为名义 0.95。全部条件的连续缺失时长为 34 步、10.2 个模型时间单位；独立统计单位为 5 个种子。

5.5.4 同状态输入重建与闭环响应

表 4 中，中心条件的同状态输入误差从 drop 的 0.5143 降至 drop-normalized 的 0.2671，说明恢复总幅值能够补偿部分输入差异。hold 进一步降至 0.05507，KF-mean 降至 0.02103，相对 hold 降低 61.8%。二者使用相同的缓存权重，差异来自缺失期间的方向外推，表明预测方位能够在保持历史输入的基础上进一步重建当前方向场。

表 4: 中心条件下五个种子的平均响应。$h = 4$、random、$A_0 = 0.228$；输入误差在同一 fresh 状态上计算，距离与 GO 在闭环恢复后 100 步计算。距离列及 GO 损失列按表头缩放；ΔD 为有符号变化，D_{abs} 为逐时刻绝对偏离的平均值。

方法	E_I	$10^3\Delta D$	$10^3 D_{\mathrm{abs}}$	10^3 GO 损失
fresh	0	0	0	0
drop	0.51426	1.60580	1.60580	−7.09418
drop-normalized	0.26710	0.07157	0.32839	−2.16612
hold	0.05507	0.58979	0.58979	−1.86953
KF-mean	0.02103	0.08120	0.08181	−1.34723

闭环层的响应体现了输入重建与群体指标之间的非线性联系。中心条件下，KF-mean 的 $\Delta D = 8.12 \times 10^{-5}$，hold 为 5.90×10^{-4}；drop-normalized 的有符号均值略低于 KF，但其绝对偏离为 3.28×10^{-4}，高于 KF 的 8.18×10^{-5}，说明符号抵消会影响单纯均值比较。四种非 fresh 分支的中心条件 GO 损失均为负，即该窗口内 GO 略高于 fresh，同时仍存在距离结构偏移，体现了有序度与凝聚响应的不同侧面。

图 8a–c 显示，增加隐藏数量使输入场重建误差上升；在七个条件中 KF-mean 的平均输入误差均低于 hold。图 8d–f 的对距变化则具有非单调性：数量扫描中 KF 的有符号变化为 6.51×10^{-5}、8.12×10^{-5}、2.74×10^{-5}；分散结构及高幅值条件的均值略为负。在 35 个种子–条件配对中，KF 相对 hold 的有符号变化和绝对偏离分别在 34 项中更低，各项共享同一批五个种子。结果支持将方位预测、输入场重建和闭环响应逐层评价：预测提供的方向信息改善了输入重建，群体指标还受神经场非线性与分叉轨迹影响。

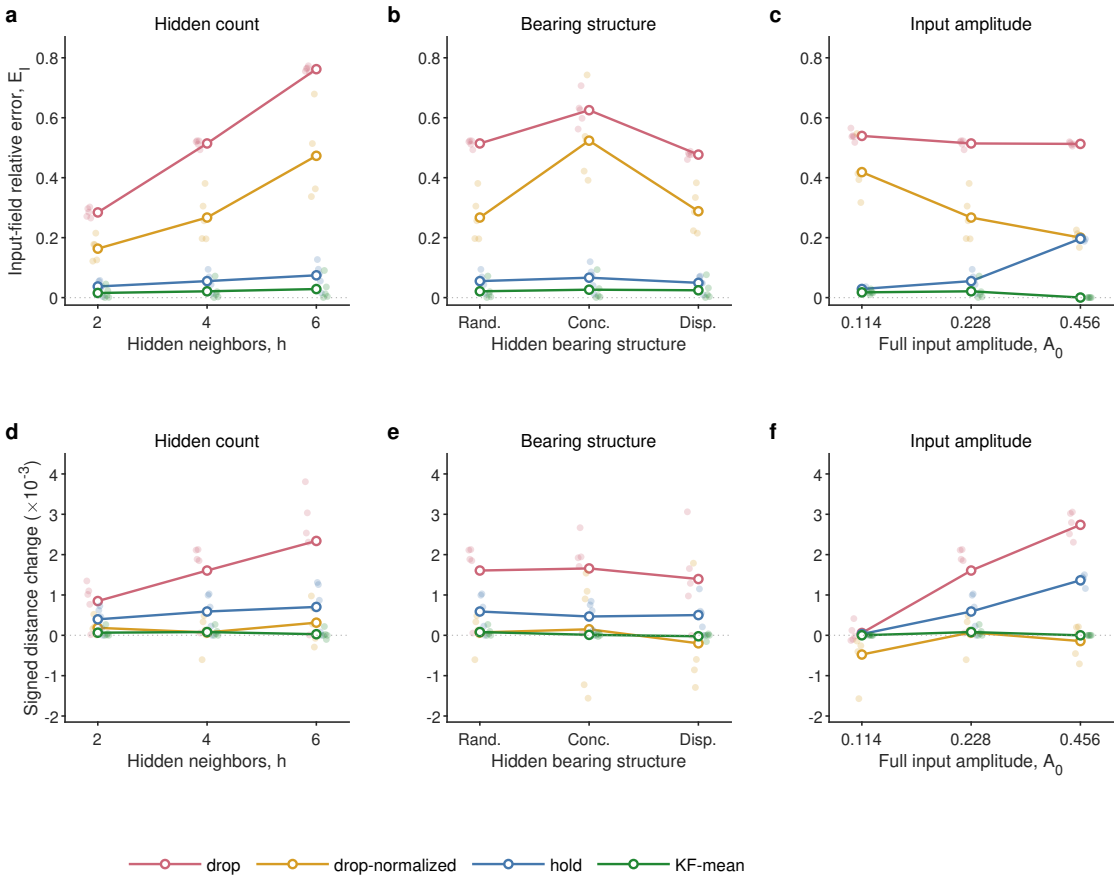


图 8: 输入重建与闭环对距响应的三条单因素扫描。（a–c）缺失期间在同一 fresh 状态上计算的完整输入场相对误差 E_I；（d–f）恢复后 100 步的有符号对距变化 ΔD，纵轴单位为 10^{-3}。各列分别改变隐藏数量、方位结构和完整观测总幅值，中心条件与图 7 一致。连线点为五种子均值，浅色散点为逐种子值；零线对应 fresh 参考。负值表示相对 fresh 更紧凑，连线用于辨识三个离散水平。

5.6 扩展遮挡时长下的闭环补偿结果

为避免长遮挡下轨迹分叉导致 GO 符号偶然变化，主响应采用相对无遮挡控制的绝对偏差。记 $\mathcal{K}_o$ 为一次连续遮挡覆盖的时间步集合，遮挡期 GO 偏差定义为

$$D_{\mathrm{GO}} = \frac{1}{|\mathcal{K}_o|} \sum_{k \in \mathcal{K}_o} \left| GO_{\mathrm{control}}(k) - GO_{\mathrm{method}}(k) \right|, \tag{102}$$

遮挡后凝聚距离偏差采用相同定义。配对改善量由同一随机种子的方法差值与 fresh-drop 损失计算，区间由 5000 次 bootstrap 重采样得到。

表 5 和表 6 分别给出隐藏 11/15 条输入时 GO 偏差与遮挡后凝聚距离偏差的配对改善。百分比相对 fresh-drop 计算，同时列出 hold-last，以避免把保留最后一次方位本身带来的收益误归因于 Kalman 外推。表中所有相对 fresh-drop 的 95% bootstrap 区间均不跨零。

表 5: 隐藏 11/15 条输入时 GO 偏差相对 fresh-drop 的降低比例

T	hold-last	KF-mean	KF-uncertainty	KF-GM-uncertainty
3.0	81.6%	86.4%	86.2%	86.5%
6.0	75.0%	82.3%	82.3%	83.3%
10.2	68.6%	77.9%	77.0%	79.5%
18.0	63.5%	71.5%	67.7%	72.7%
30.0	58.2%	63.1%	52.6%	62.6%
60.0	47.9%	46.9%	33.7%	46.4%

表 6: 隐藏 11/15 条输入时遮挡后距离偏差相对 fresh-drop 的降低比例

T	hold-last	KF-mean	KF-uncertainty	KF-GM-uncertainty
3.0	89.3%	89.7%	89.8%	91.3%
6.0	85.5%	89.7%	89.4%	91.2%
10.2	79.3%	89.0%	86.5%	87.0%
18.0	70.1%	88.1%	83.4%	80.1%
30.0	59.0%	85.6%	79.5%	71.5%
60.0	40.2%	59.0%	64.0%	55.3%

hold-last 在短中时遮挡中解释了大部分偏差降低。Kalman 的额外改善随指标和时间尺度变化：在表 5 的代表性条件下，$T \le 30$ 时 KF-mean 和 KF-GM 的 GO 偏差低于 hold-last；$T = 60$ 时，两者的均值略高于 hold-last。KF-uncertainty 对遮挡后距离偏差的改善更稳定，在 $T = 60$ 时相对 fresh-drop 降低约 64%，高于 hold-last 的 40.2%。这体现了协方差卷积对过期方向输入的抑制，以及该作用在有序度与凝聚恢复上的差异。

图 10 直接给出各 Kalman 方法相对 hold-last 的配对差值。负值表示相对 hold-last 降低偏差。该图用于区分“保留旧方位已带来的收益”和“Kalman 外推或协方差卷积额外带来的收益”：短时遮挡中多数 Kalman 增量很小，中时遮挡中 KF-mean 和 KF-GM 对 GO 有可见增益，而 KF-uncertainty 的优势主要体现在长时间遮挡后的凝聚结构。

5.7 遮挡前受控转向与相对退化指标

为检验动态方向变化中的预测补偿，本文设置受控转向干预。首先从同一无遮挡检查点分叉；在遮挡开始前 20 步（6 个模型时间单位），对编号为 1–3 的领航个体施加弱的异中心旋转方向输

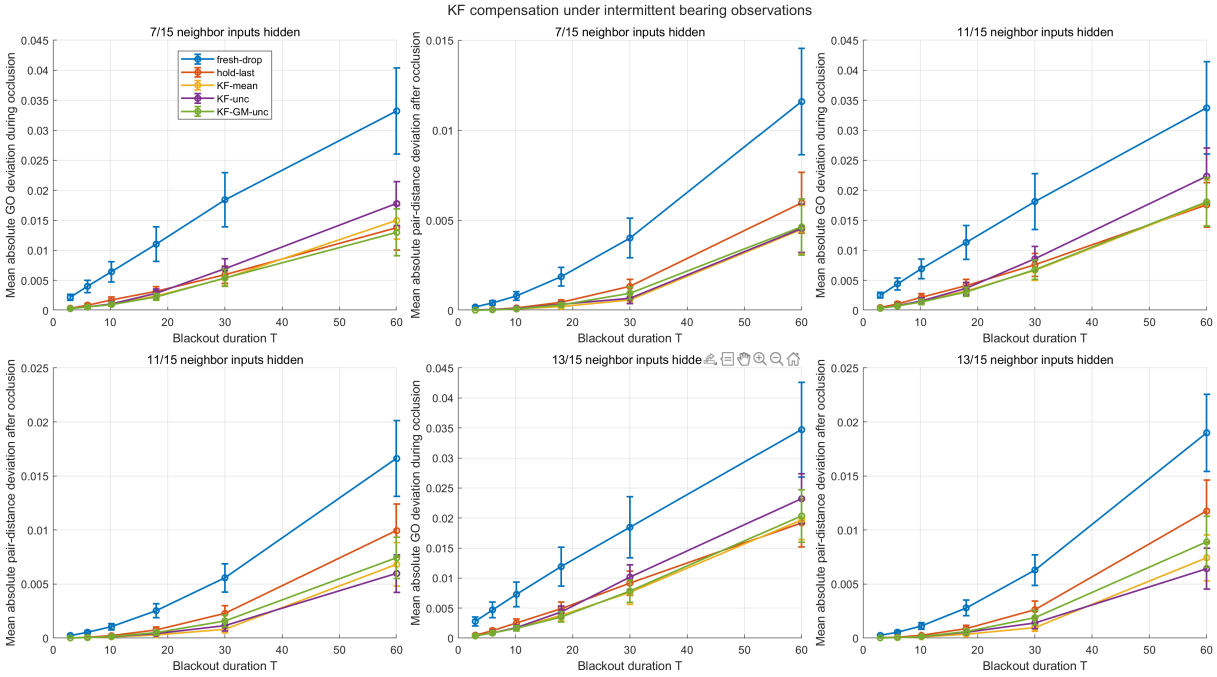


图 9: 不同遮挡强度和时长下的绝对 GO 偏差与遮挡后距离偏差。误差线为种子间近似 95% 置信区间。

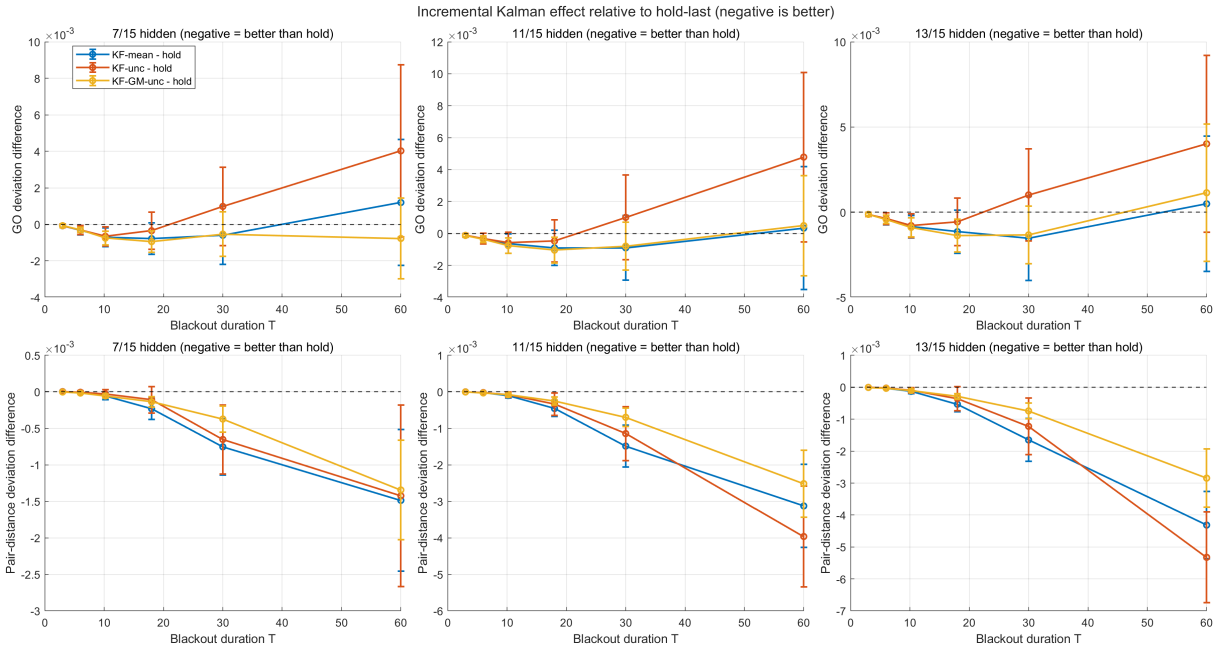


图 10: Kalman 方法相对 hold-last 的配对差值。横轴为遮挡时长，负值表示偏差低于 hold-last。

入，领航方向以 0.025 rad/模型时间的角速度缓慢变化。遮挡在第 201 步开始，期间领航个体继续转向；其余个体通过邻居方位输入跟随。Kalman 轨迹在遮挡前接收连续变化的方位观测并估计方位角速度，遮挡开始时跟随者仍处于向新共同方向调整的过程中。

受控转向实验仍比较 fresh-drop、hold-last、KF-mean、KF-uncertainty 和 KF-GM-uncertainty。每个方法与同一转向任务下的无遮挡控制轨迹配对。除绝对 GO、LO 和凝聚距离外，定义相对退化指标

$$D_{\mathrm{GO}}^{\mathrm{rel}} = \frac{\mathrm{mean}_{k\in\mathcal{K}_o} |GO_{\mathrm{method}}(k) - GO_{\mathrm{control}}(k)|}{\mathrm{mean}_{k\in\mathcal{K}_o} |GO_{\mathrm{control}}(k)|}, \tag{103}$$

并以相同方式定义 $D_{\mathrm{LO}}^{\mathrm{rel}}$ 和遮挡后凝聚距离相对偏差 $D_{\mathrm{pair}}^{\mathrm{rel}}$。这些指标比较的是观测缺失造成的相对退化，而不是不同模型本来具有的绝对性能差异。

图 11 给出干预时序。图 12 给出完整 30 个种子在 11/15 条有向边隐藏条件下的统计结果。以 $T = 3$ 和 $T = 10.2$ 为例，fresh-drop 的相对 GO 退化分别为 0.99% 和 2.82%，KF-GM-uncertainty 分别为 0.13% 和 0.45%；对应的遮挡后相对凝聚距离偏差分别为 0.127% 和 0.605%，KF-GM-uncertainty 分别降至 0.0085% 和 0.090%。完整矩阵表明，遮挡前转向确实放大了无预测补偿分支的退化，而 Kalman 分支在 GO 和凝聚结构指标上均保持较低偏差；误差线为 30 个种子间的近似 95% 置信区间。

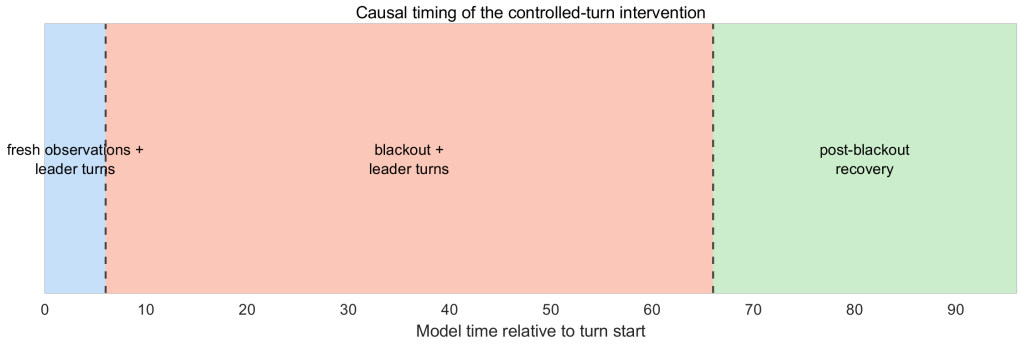


图 11: 受控转向实验时序：遮挡前先开始领航转向，随后进入连续遮挡和恢复窗口。

5.8 与主流集群模型的参考比较

表 7 给出 $T = 30$、隐藏 7/15 条输入时与 Vicsek、Boids 和 Olfati–Saber 型模型的辅助比较。其中，Vicsek 型模型源于自驱动粒子模型 [7]，其宏观集体运动机制可进一步参见相关综述 [27]；Olfati–Saber 型模型采用连续时间一致性框架和势函数构造 flocking 控制 [5]。主流模型使用邻居航向或相对位置，本文方法只使用方位观测，因此该比较用于说明额外状态信息带来的性能上界和代价，而不是同传感器条件下的算法排序。需要特别指出，这一辅助比较不包含与本文等价的方位预测器；若遮挡发生在已经充分收敛的直线运动阶段，主流模型仍可能依靠剩余可见邻居和自身状态维持较高 GO。因此，本文不使用该图单独证明 Kalman 的遮挡收益，Kalman 的因果效果以受控转向配对实验为主要证据。

图 13 和表 7 展示不同感知条件下的性能–代价差异：本文方法基于方位观测维持群体有序运动，并保持较低转向控制量；Boids 和 Olfati–Saber 型基线使用相对位置，结合排斥或势函数项，在最近距离和危险接近时间占比方面表现更好。这一差异提示了方位驱动模型进一步结合显式避碰约束的研究方向。

图 13 和表 7 中，记 $d_{\min}$ 为最小个体间距离，d_{safe} 为危险接近诊断阈值，R_{dp} 为最小距离不超过 d_{safe} 的时间步比例。上述诊断量不进入控制器，也不构成碰撞安全保证。

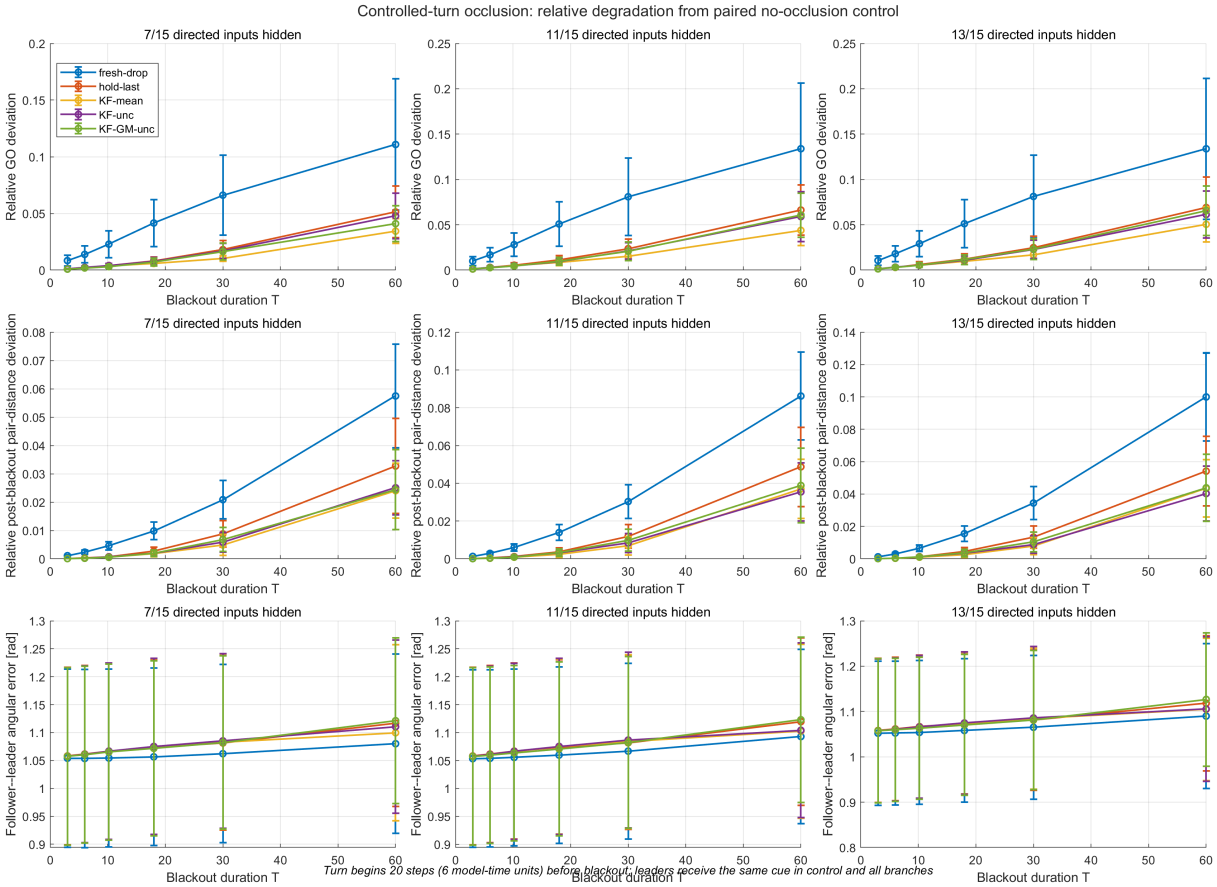


图 12: 受控转向下相对无遮挡控制的退化（完整 30 个种子）。误差线为种子间近似 95% 置信区间。

表 7: 与主流集群模型的参考比较（种子 101–105，$T = 30$）

模型	遮挡期 GO	GO 损失	最小距离 $/L$	危险接近时间占比
本文 KF-uncertainty	0.729	−0.0014	0.00056	0.872
Vicsek（邻居航向）	1.000	0	0.00760	0.800
Boids（位置 + 航向）	0.975	0.0038	0.00773	0.064
Olfati–Saber 型（位置 + 航向）	0.911	0.0368	0.00764	0.031

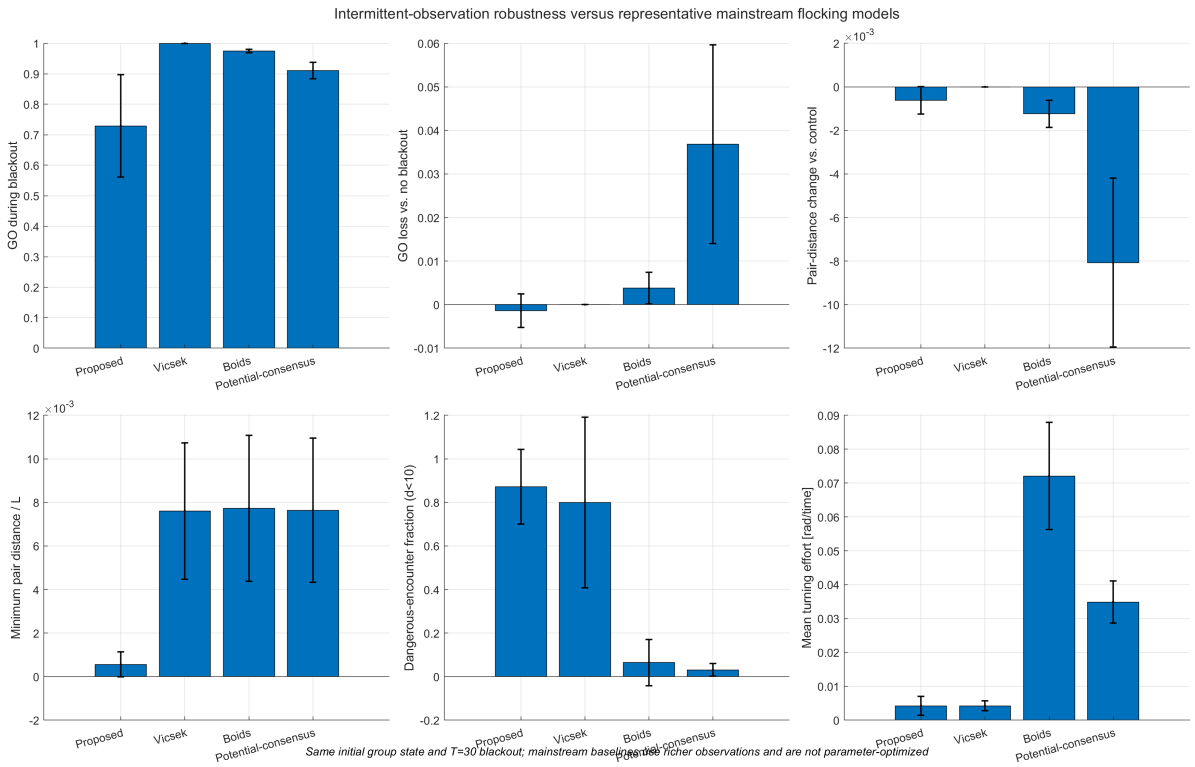


图 13: 与主流集群模型的参考比较。危险接近比例按仿真距离阈值统计，用于诊断近距离风险。

5.9 实验条件与后续验证

上述闭环结果来自固定邻居身份、等权输入和脚本化连续遮挡条件；阻尼模型参数在前期开发阶段选定，新种子闭环评估沿用这些参数。下一步将以预测区间的实际覆盖率校准协方差，并扩展到动态邻居集合和真实几何遮挡。数据关联、邻居存在概率和碰撞约束需要相应的估计与控制模块。

6 讨论

社会输入经验模型通过 $S_i = n_i \bar{w}_i C_i$ 将数量、强度与方位结构组织为可分解的输入量。受控实验验证了正前方输入的线性累加，以及固定总幅值时方位结构对 C_i 的影响；随机几何分组交叉验证中，指数加权模型较幅值基准降低局部纵向响应预测 RMSE 16.1%，并在 18/20 个几何组中获得更低误差。这说明方位权重补充了总幅值之外的响应信息。经验量采用正值累加，而纵向运动输出由完整神经场产生并具有方向符号；神经场的非线性、饱和和对称解码共同影响二者的关系。后续将结合群体轨迹分析 S_i 与 GO、LO 及凝聚距离的联系，并检验不同 κ 下的适用范围。

挑战二的分层实验将历史方位预测与输入重建联系起来。在相同 fresh 状态下，幅值归一化、历史方位保持和均值预测依次降低中心条件的输入场误差；KF-mean 相对 hold 降低 61.8%，说明方向外推能够补充历史方位记忆。低幅值条件中，方位 RMSE 增大而输入场误差仍减小，表明输入核、方位分布与误差方向共同决定重建效果。闭环对距响应又具有非单调性，因此方位误差、输入误差与群体指标需要分别解释。五种子结果同时显示协方差覆盖率存在轨迹差异，为下一步校准提供了依据。

方位–角速度预测器适合局部连续角度演化。长时间中断、快速转弯和周期边界最近镜像切换需要更灵活的运动模型与轨迹管理；当前最近邻和方位平衡策略中使用仿真距离的部分作为机制

对照。预测器与神经场目前采用单向接口，神经场意图反馈至预测噪声的双向耦合是后续可研究的方向。

更广泛的群体运动还涉及流体耦合等机制 [28]。参数不确定性下的预测控制与灵敏度分析 [29] 可用于将预测误差纳入风险约束；分布式部署则需要结合恶意节点下的估计方法 [30] 以及多跳通信中的拓扑与资源管理 [31]。这些扩展可在现有方位输入与预测接口上逐步引入。

7 结论

本文提出了一个面向间歇方位观测的异中心神经场 Kalman 预测补偿框架。该框架从异中心神经场模型出发，构建基于指数方位权重的邻居社会输入经验量化模型，通过单邻居输入的正值累加，将邻居数量、输入强度和相对自身朝向的方位结构统一为可计算指标，并分解观测缺失造成的幅值变化与方位权重变化；再使用方位—方位角速度 Kalman 滤波器在观测缺失期间预测已跟踪邻居的方位，并将预测协方差通过圆周核卷积传递给神经场。理论分析表明，连续缺失会导致方位协方差按时间累积，圆周方向的高阶结构按 $e^{-n^2V/2}$ 衰减；在给定后验模型下，协方差卷积输入具有条件均方最优的输入重建性质。

三个经验模型实验验证了数量–强度的累加关系和固定总幅值下的方位加权差异；在 20 组随机几何、240 个配对条件的分组交叉验证中，指数加权输入较总幅值基准降低局部纵向响应预测 RMSE 16.1%。

方位预测、同状态输入重建与闭环响应的分层机制实验表明，在固定八邻居、隐藏四邻居、总幅值 0.228 的中心条件下，KF-mean 较 hold 降低逐种子方位 RMSE 均值 26.4%，降低同状态输入场误差 61.8%。五种子开发结果同时揭示了方位预测精度、输入重建误差和闭环群体指标之间的不同响应关系。扩展遮挡时长的配对实验表明，Kalman 预测补偿相对 fresh-drop 降低了 GO 偏差和遮挡后凝聚距离偏差，额外收益随指标与遮挡时长变化。KF-GM-uncertainty 进一步提高了隐藏边的方位预测精度。下一步将开展经验输入量与群体有序性、凝聚性的关联分析，以及预测协方差校准、独立种子验证、邻居存在概率建模、真实几何遮挡与碰撞约束扩展。

参考文献

[1] C. Bai, P. Yan, H. Piao, W. Pan, and J. Guo, “Learning-based multi-UAV flocking control with limited visual field and instinctive repulsion,” *IEEE Transactions on Cybernetics*, vol. 54, no. 1, pp. 462–475, 2024, doi: 10.1109/TCYB.2023.3246985.

[2] M. Boldrer, V. Kratky, V. Walter, and M. Saska, “Distributed Lloyd-based algorithm for uncertainty-aware multi-robot under-canopy flocking,” *IEEE Robotics and Automation Letters*, vol. 11, no. 5, pp. 5526–5533, 2026, doi: 10.1109/LRA.2026.3673985.

[3] C. Li, Y. Yang, T.-Y. Huang, and X.-B. Chen, “An improved flocking control algorithm to solve the effect of individual communication barriers on flocking cohesion in multi-agent systems,” *Engineering Applications of Artificial Intelligence*, vol. 137, art. 109110, 2024, doi: 10.1016/j.engappai.2024.109110.

[4] X. Ge, Q.-L. Han, X.-M. Zhang, D. Ding, and B. Ning, “Distributed coordination control of multi-agent systems under intermittent sampling and communication: a comprehensive survey,” *Science China Information Sciences*, vol. 68, no. 5, art. 151201, 2025, doi: 10.1007/s11432-024-4355-1.

[5] R. Olfati-Saber, “Flocking for multi-agent dynamic systems: algorithms and theory,” *IEEE Transactions on Automatic Control*, vol. 51, no. 3, pp. 401–420, 2006, doi: 10.1109/TAC.2005.864190.

[6] C. W. Reynolds, “Flocks, herds and schools: A distributed behavioral model,” in *Proceedings of SIGGRAPH ’87*, pp. 25–34, 1987, doi: 10.1145/37401.37406.

[7] T. Vicsek, A. Czirók, E. Ben-Jacob, I. Cohen, and O. Shochet, “Novel type of phase transition in a system of self-driven particles,” *Physical Review Letters*, vol. 75, no. 6, pp. 1226–1229, 1995, doi: 10.1103/PhysRevLett.75.1226.

[8] M. Salahshour and I. D. Couzin, “Allocentric flocking,” *Nature Communications*, vol. 16, art. 9051, 2025, doi: 10.1038/s41467-025-64676-5.

[9] A. H. Xiouroupa, D. Mikhin, M. Humphries, and J. Maclean, “Theoretical insights for bearings-only tracking in log-polar coordinates,” *IEEE Transactions on Aerospace and Electronic Systems*, vol. 61, no. 4, pp. 8534–8545, 2025, doi: 10.1109/TAES.2025.3547317.

[10] K. Zhang, “Representation of spatial orientation by the intrinsic dynamics of the head-direction cell ensemble: a theory,” *The Journal of Neuroscience*, vol. 16, no. 6, pp. 2112–2126, 1996, doi: 10.1523/JNEUROSCI.16-06-02112.1996.

[11] Z. Chen, H. Wang, J. Li, G. Li, and S. Wang, “Egocentric head direction encoding and perception model based on an adaptive ring attractor network,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 37, no. 8, pp. 3900–3912, 2026, doi: 10.1109/TNNLS.2026.3656687.

[12] P. Ao, “Towards predictive neural network dynamical theory,” *Physics of Life Reviews*, vol. 36, pp. 30–32, 2021, doi: 10.1016/j.plrev.2020.08.006.

[13] Z. Lu, J. B. Julian, G. K. Aguirre, and R. A. Epstein, “A neural compass in the human brain during naturalistic virtual navigation,” *The Journal of Neuroscience*, vol. 45, no. 34, art. e1765242025, 2025, doi: 10.1523/JNEUROSCI.1765-24.2025.

[14] D. L. Krongauz, A. Ayali, and G. A. Kaminka, “Vision-based collective motion: a locust-inspired reductionist model,” *PLOS Computational Biology*, vol. 20, no. 1, art. e1011796, 2024, doi: 10.1371/journal.pcbi.1011796.

[15] K. Li, L. Li, R. Gross, and S. Zhao, “A collective perception model for neighbor selection in groups based on visual attention mechanisms,” *New Journal of Physics*, vol. 26, no. 1, art. 012001, 2024, doi: 10.1088/1367-2630/ad1b81.

[16] K. Xue, D. Kong, P. Wang, Z. Xu, and Z. Huang, “Attention-based selective interaction model for self-organized collective motion,” *Chaos, Solitons & Fractals*, vol. 201, art. 117320, 2025, doi: 10.1016/j.chaos.2025.117320.

[17] J. Qi, Z. Zhang, J. Yu, X. Dong, Q. Li, and H. Jiang, “Time-varying group formation tracking control for multi-agent systems using distributed multi-sensor multi-target filtering with intermittent observations,” *International Journal of Robust and Nonlinear Control*, vol. 34, no. 17, pp. 11681–11704, 2024, doi: 10.1002/rnc.7587.

[18] Y. Pan, T. Chen, Q. Qi, H. Tian, and W. Kong, "Bearing-only target tracking for multi-UUV via IMM-UIF with initial filter value correction," *Ocean Engineering*, vol. 356, art. 125347, 2026, doi: 10.1016/j.oceaneng.2026.125347.

[19] Q. Ge, Y. Li, Y. Wang, X. Hu, H. Li, and C. Sun, "Adaptive Kalman filtering based on model parameter ratios," *IEEE Transactions on Automatic Control*, vol. 69, no. 9, pp. 6230–6237, 2024, doi: 10.1109/TAC.2024.3376306.

[20] K. Zhang, H. Wang, W. Chen, J. Ren, N. Luo, and Z. Lu, "Multiplatform bearing-only target tracking algorithm based on maximum likelihood maximum correntropy Kalman filter," *IEEE Sensors Journal*, vol. 25, no. 7, pp. 11366–11377, 2025, doi: 10.1109/JSEN.2025.3529771.

[21] Q. Yu, Z. Fan, X. Bu, and Z. Hou, "Event-triggered based predictive iterative learning control with random packet loss compensation for nonlinear networked systems," *ISA Transactions*, vol. 148, pp. 169–181, 2024, doi: 10.1016/j.isatra.2024.03.001.

[22] D. Selvi and G. Battistelli, "Distributed Kalman filtering with adaptive communication," *IEEE Control Systems Letters*, vol. 9, pp. 15–20, 2025, doi: 10.1109/LCSYS.2025.3550401.

[23] H. Zhou and S. Sun, "Distributed extended Kalman consensus filtering for multi-sensor networked nonlinear systems under stochastic communication protocol," *IEEE Transactions on Signal Processing*, vol. 73, pp. 3629–3640, 2025, doi: 10.1109/TSP.2025.3599848.

[24] T. Yang, J. Qian, Z. Duan, and Z. Sun, "Distributed Kalman filter with ultimately accurate fused measurement covariance," *IEEE Transactions on Automatic Control*, vol. 70, no. 10, pp. 6449–6464, 2025, doi: 10.1109/TAC.2025.3557365.

[25] D. Rong and Y. Wang, "An adaptive spatial target tracking method based on unscented Kalman filter," *Sensors*, vol. 24, no. 18, art. 6094, 2024, doi: 10.3390/s24186094.

[26] B. Sinopoli, L. Schenato, M. Franceschetti, K. Poolla, M. I. Jordan, and S. S. Sastry, "Kalman filtering with intermittent observations," *IEEE Transactions on Automatic Control*, vol. 49, no. 9, pp. 1453–1464, 2004, doi: 10.1109/TAC.2004.834121.

[27] T. Vicsek and A. Zafeiris, "Collective motion," *Physics Reports*, vol. 517, no. 3–4, pp. 71–140, 2012, doi: 10.1016/j.physrep.2012.03.004.

[28] X. Mao, J. Wang, X. Mao, and J. Deng, "A hybrid numerical model for the collective motion of fish groups," *Journal of Fluid Mechanics*, vol. 1009, art. A26, 2025, doi: 10.1017/jfm.2025.216.

[29] T. Belvedere, M. Cognetti, G. Oriolo, and P. R. Giordano, "Sensitivity-aware model predictive control for robots with parametric uncertainty," *IEEE Transactions on Robotics*, vol. 41, pp. 3039–3058, 2025, doi: 10.1109/TRO.2025.3554415.

[30] L. An and G.-H. Yang, "Mean-square exponential convergence for Byzantine-resilient distributed state estimation," *Automatica*, vol. 163, art. 111592, 2024, doi: 10.1016/j.automatica.2024.111592.

[31] R. Gao, G.-H. Yang, and S. Wasly, "Resilient distributed state estimation with multi-hop communication," *Automatica*, vol. 168, art. 111823, 2024, doi: 10.1016/j.automatica.2024.111823.